Анализ данных «Барометра Центральной Азии», продолжение

Ryan Womack

2026-04-07

Copyright Ryan Womack, 2026. Данная работа распространяется под лицензией CC BY-NC-SA 4.0

Анализ данных Барометра Центральной Азии, продолжение

Обработка данных, разведочный анализ данных и визуализация данных Центральноазиатского Барометра.

первоначально разработано для презентации на Американский Университет Центральной Азии, Весна 2026

[Обратите внимание: русский текст переведен с английского с помощью машинного перевода]

1 Обзор

Этот семинар иллюстрирует работу с данными, продолжая материал Барометр Центральной Азии 1, в котором была представлена работа с данными по одной волне и стране из Барометра Центральной Азии (Кыргызстан в 2022 году). Вторая часть иллюстрирует работу с данными по нескольким волнам и странам, демонстрируя более сложные методы объединения и очистки данных, дополнительные возможности построения графиков и предлагая отправные точки для статистического анализа. Код написан на языке R, но для тех, кто хочет повторить шаги, доступна версия материала на Python (машинный перевод). И R, и Python — отличные инструменты для анализа данных, поэтому в некоторой степени ваш выбор — это вопрос предпочтений и знакомства с языком. Язык R возник из статистики и добавил вычислительные возможности, в то время как Python — это универсальный язык программирования, к которому были добавлены значительные статистические возможности.

2 Установка

Данный семинар *не* охватывает установку R и RStudio, но предполагает наличие у вас рабочей копии этих программ.

R — это программное обеспечение с открытым исходным кодом для статистического анализа, доступное по адресу R-project.org. Рекомендуется сначала установить R. Команды R можно выполнять во многих редакторах и IDE, непосредственно в терминале или через скриптовые файлы. Однако один из самых мощных и распространенных методов, который мы будем использовать здесь, — это использование IDE RStudio.

RStudio, доступный на Posit в виде загрузки с открытым исходным кодом, — это инструмент для создания и запуска кода на языке R (а также на Python и нескольких других языках), обладающий множеством полезных функций и шаблонов для работы с другими форматами и инструментами в экосистеме R. RStudio будет использовать установленную вами версию R, работая как надстройка над ней. Posit также разрабатывает Positron — более новую IDE с большей гибкостью для работы с R, Python и другими возможными языками. В этом мастер-классе не используется Positron, хотя код должен работать и там.

И RStudio, и Positron внедряют в свои интерфейсы инструменты подсказок на основе искусственного интеллекта, которые, как утверждается, работают с конкретным кодом вашего проекта и понимают его. Их следует предпочитать использованию сторонних сервисов, таких как ChatGPT.

Для немедленного использования без установки попробуйте следующее:

- Posit Cloud — это также бесплатный сервис, позволяющий использовать RStudio (с некоторыми ограничениями по времени и памяти) после создания учетной записи.

Более подробную информацию можно найти в видеоролике Начало работы с R (или в других веб-уроках и руководствах).

Python также является языком с открытым исходным кодом и может использоваться с различными редакторами и инструментами, которые здесь не описаны подробно.

2.1 R помощь

Система справки R легкодоступна. Используйте вопросительный знак перед именем конкретной функции, чтобы открыть ее страницу руководства (*?sample* или *?rnorm*). Используйте два вопросительных знака для поиска. Вкладка «Справка» в правом нижнем углу RStudio также предоставляет полный доступ к встроенной справке, включая руководства и поиск.

Поиск в интернете справки по R может быть полезен, поскольку существует множество руководств, статей в блогах и других материалов по общим методам и конкретным пакетам R. Полезно добавить к поисковому запросу что-то вроде «статистика R», «программное обеспечение R» или «пакет R», чтобы отличать его от всех других случаев использования буквы R!

3 Настройка и подготовка данных

3.1 Необходимые пакеты R

Для установки мы будем использовать пакет *pak*, поскольку это более полный подход к управлению пакетами. При желании замените команды pkg на версии, созданные с помощью *install.packages()*.

В этом занятии предпочтительно используется набор пакетов *tidyverse* для обработки данных, хотя те же задачи можно выполнить в базовом R с помощью других функций. Установите *pak* и *tidyverse*, если они еще не установлены в вашей системе. Нам также понадобится *reticulate* для запуска фрагментов кода Python.

Для построения графиков большую часть работы выполнит пакет *ggplot2*, но также будут использоваться *lattice* и несколько специализированных вспомогательных пакетов.

```
install.packages("pak", dependencies=TRUE)
library(pak)
pkg_install("tidyverse")
pkg_install("readxl")
pkg_install("reticulate")
pkg_install("ggplot2") # including in tidyverse, but just making this
 ↪  explicit
pkg_install("lattice")

# helper packages

pkg_install("ggthemes")
pkg_install("cowplot")
pkg_install("gridExtra")
pkg_install("RColorBrewer")
pkg_install("png")
pkg_install("paletteer")
pkg_install("ggiraph")

# pkg_install("ggridges")
# pkg_install("ggvis")
# pkg_install("gganimate")
# pkg_install("gapminder")
# pkg_install("hexbin")
# pkg_install("gifski")

devtools::session_info()
```

Обратите внимание, что команду *update.packages()* можно периодически запускать для проверки наличия более новых версий установленных пакетов.

Загрузите пакеты заранее, чтобы мы могли с ними работать.

```
library(readxl)
library(tidyverse)
```

```
-- Attaching core tidyverse packages ------------------------ tidyverse 2.0.0 --
v dplyr     1.2.1     v readr     2.2.0
v forcats   1.0.1     v stringr   1.6.0
v ggplot2   4.0.2     v tibble    3.3.1
v lubridate 1.9.5     v tidyr     1.3.2
v purrr     1.2.1
-- Conflicts ------------------------------------------ tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```r
library(lattice)
library(ggthemes)
library(cowplot)
```

```
Attaching package: 'cowplot'

The following object is masked from 'package:ggthemes':

    theme_map

The following object is masked from 'package:lubridate':

    stamp
```

```r
library(gridExtra)
```

```
Attaching package: 'gridExtra'

The following object is masked from 'package:dplyr':

    combine
```

```r
library(RColorBrewer)
library(png)
library(paletteer)
library(ggiraph)
```

3.2 Версии

Ссылки справа предоставляют альтернативные способы доступа к этому контенту. Вы можете выбрать светлый или темный режим HTML, загрузить PDF-файл или файл Word в формате Docx — все они будут содержать один и тот же контент. Также доступны файлы кода на языке R (.R) или Python (.py), если вы хотите отделить код от описания.

3.3 Кыргызский и русский языки

Кроме того, справа приведены ссылки на машинный перевод этого контента на русский и киргизский языки.

3.4 поддержка Python

Теперь загрузим *reticulate* (только для поддержки Python). Необходимо указать правильное местоположение Python, соответствующее нашей системе.

Для тех, кто хочет попробовать выполнить те же шаги обработки данных на Python, прилагается файл Python. Обратите внимание, что файл Python был переведен с языка R машинным способом и, вероятно, нуждается в доработке!

```
# Sys.setenv(RETICULATE_PYTHON = "/usr/bin/python3")
library(reticulate)
use_python("/usr/bin/python3")
```

4 Барометр Центральной Азии

Как обсуждалось на предыдущем семинаре, проект Барометр Центральной Азии проводит опросы и исследования в странах Центральной Азии (Казахстан, Кыргызстан, Таджикистан, Туркменистан и Узбекистан) и регулярно публикует результаты. За исключением последней волны данных, данные Барометра Центральной Азии можно бесплатно загрузить с их веб-сайта, указав контактный адрес электронной почты. Эти опросы изучают современные политические и социальные взгляды и позволяют проводить долгосрочные сравнения, а также межстрановые сравнения.

На этом семинаре мы объединим девять файлов с результатами опросов по Казахстану, Кыргызстану и Узбекистану за 4, 8 и 12 волны, представляющие осень 2018, 2020 и 2022 годов соответственно. Хотя это более управляемо, чем попытка объединить данные по всем странам за еще большее количество волн, это дает нам представление о большей сложности, связанной со сравнениями между странами и во времени.

4.1 Анализ данных

Прежде чем приступать к программированию или статистическому анализу, первым шагом в работе с реальными данными является понимание их структуры и смысла. Нам нужно знать, какие данные были собраны, как они организованы, и подумать, на какие вопросы они могут ответить. Только тогда мы сможем понять, как правильно приступить к их анализу.

Для CA Barometer это означает изучение множества файлов. Как и прежде, вам нужно будет заполнить форму на сайте CA Barometer, прежде чем ссылки станут доступны. Полный список приведен ниже:

2018 - Wave 4

Отчет о методах работы

Questionnaires: ENG, Kazakh, Kyrgyz, Uzbek

Data: Kazakhstan, Kyrgyzstan, Uzbekistan

2020 - Wave 8

Отчет о методах работы

Анкеты: ENG, RUS

Данные: Kazakhstan, Kyrgyzstan, Uzbekistan

2022 - Wave 12

Отчет о методах работы

Анкета: ENG

Данные: Kazakhstan, Kyrgyzstan, Uzbekistan

5 Загрузка и импорт данных

Мы загружаем данные из Центральноазиатского барометра, используя ссылки выше. Обратите внимание, что также предоставлены ссылки на Таджикистан и Туркменистан, но мы не будем использовать их на этом семинаре.

```
download.file("https://ca-barometer.org/assets/files/projects/cab-survey-wave-12-excel-kyrgyzs
↪  "CAB_2022_KG.csv")
data_22_KG <- read_excel("CAB_2022_KG.csv")

download.file("https://ca-barometer.org/assets/files/projects/cab-survey-wave-12-excel-kazakhs
↪  "CAB_2022_KZ.csv")
data_22_KZ <- read_excel("CAB_2022_KZ.csv")

download.file("https://ca-barometer.org/assets/files/projects/cab-survey-wave-12-excel-uzbekis
↪  "CAB_2022_UZ.csv")
data_22_UZ <- read_excel("CAB_2022_UZ.csv")

download.file("https://ca-barometer.org/assets/files/projects/cab-survey-wave-12-excel-turkmen
↪  "CAB_2022_TM.csv")
data_22_TM <- read_excel("CAB_2022_TM.csv")

download.file("https://ca-barometer.org/assets/files/projects/cab-survey-wave-12-excel-tajikis
↪  "CAB_2022_TJ.csv")
data_22_TJ <- read_excel("CAB_2022_TJ.csv")

# download 2020 data

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
↪  "CAB_2020_KG.csv")
```

```
data_20_KG <- read_excel("CAB_2020_KG.csv")

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2020_KZ.csv")
data_20_KZ <- read_excel("CAB_2020_KZ.csv")

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2020_UZ.csv")
data_20_UZ <- read_excel("CAB_2020_UZ.csv")

# no 2020 Turkmenistan data
#
 ↪  download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-surve
 ↪  "CAB_2020_TM.csv")
# data_20_TM <- read_excel("CAB_2020_TM.csv")

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2020_TJ.csv")
data_20_TJ <- read_excel("CAB_2020_TJ.csv")

# download 2018 data

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2018_KG.csv")
data_18_KG <- read_excel("CAB_2018_KG.csv")

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2018_KZ.csv")
data_18_KZ <- read_excel("CAB_2018_KZ.csv")

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2018_UZ.csv")
data_18_UZ <- read_excel("CAB_2018_UZ.csv")

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2018_TM.csv")
data_18_TM <- read_excel("CAB_2018_TM.csv")

download.file("https://ca-barometer.org/assets/files/projects/central-asia-barometer-survey-wa
 ↪  "CAB_2018_TJ.csv")
data_18_TJ <- read_excel("CAB_2018_TJ.csv")
```

6 Объединение данных

Теперь нам нужно объединить данные. В процессе мы обнаруживаем некоторые несоответствия, которые необходимо устранить, чтобы объединить данные в один согласованный файл. Например, страна иногда обозначается аббревиатурой, а иногда —

переменной MM4.

```
data_22_KG <- mutate(data_22_KG, Country = 'Kyrgyzstan')
data_20_KG <- mutate(data_20_KG, Country = 'Kyrgyzstan')

# data_18_KG <- mutate(data_18_KG, Country = 'KG')

data_22_KZ <- mutate(data_22_KZ, Country = 'Kazakhstan')
data_20_KZ <- mutate(data_20_KZ, Country = 'Kazakhstan')

# data_18_KZ <- mutate(data_18_KZ, Country = 'KZ')

data_22_UZ <- mutate(data_22_UZ, Country = 'Uzbekistan')
data_20_UZ <- mutate(data_20_UZ, Country = 'Uzbekistan')

# data_18_UZ <- mutate(data_18_UZ, Country = 'UZ')

data_22_TM <- mutate(data_22_TM, Country = 'Turkmenistan')

# data_20_TM <- mutate(data_20_TM, Country = 'TM')
# data_18_TM <- mutate(data_18_TM, Country = 'TM')

data_22_TJ <- mutate(data_22_TJ, Country = 'Tajikistan')
data_20_TJ <- mutate(data_20_TJ, Country = 'Tajikistan')

# data_18_TJ <- mutate(data_18_TJ, Country = 'TJ')
```

6.1 Пытаюсь использовать rbind.

Команда *rbind* полезна для простых, буквальных комбинаций строк данных (*cbind* эквивалентна объединению столбцов). Однако этот метод требует, чтобы все переменные идеально совпадали между объединяемыми наборами данных. При попытке это сделать мы обнаруживаем некоторые несоответствия.

```
data_2022 <- rbind(data_22_KZ, data_22_KG, data_22_UZ)
```

Это приводит к ошибке, поэтому давайте изучим различия между наборами данных с помощью *setdiff*. Затем используем *full_join* для создания объединенного набора данных, включающего все переменные. Это выявит проблему с несовместимыми форматами в файле «Год», которая будет исправлена в разделе «Очистка данных».

```
setdiff(names(data_22_KG),names(data_22_KZ))
setdiff(names(data_22_KG),names(data_22_UZ))
setdiff(names(data_22_KZ),names(data_22_UZ))

my_test_join <- full_join(data_22_KG, data_22_KZ)
```

7 Очистка данных

При более детальном изучении данных мы обнаруживаем несоответствия, например, форматирование лет. Кроме того, дата — MM6 за 2018 год, но обозначена как «Год» — нужно быть внимательными при заполнении анкет! Нас не интересует такой уровень детализации, поэтому давайте добавим в данные аналогичную переменную «Год». Это также перезапишет тип переменной, но мы можем это проверить. Наконец, переименуем все переменные в «Год» для единообразия.

```
# data_22_KG$MM8
# data_22_KZ$MM8
# data_20_KG$MM8
# data_20_KZ$MM8
# data_18_KG$MM6
# data_18_KZ$MM6

data_22_KG$MM8 <- 2022
data_22_KZ$MM8 <- 2022
data_22_UZ$MM8 <- 2022

data_20_KG$MM8 <- 2020
data_20_KZ$MM8 <- 2020
data_20_UZ$MM8 <- 2020

class(data_22_KG$MM8)
```

```
[1] "numeric"
```

```
mode(data_22_KG$MM8)
```

```
[1] "numeric"
```

```
class(data_22_KZ$MM8)
```

```
[1] "numeric"
```

```
mode(data_22_KZ$MM8)
```

```
[1] "numeric"
```

```
# data_18_KG$Year
# data_18_KZ$Year

class(data_18_KG$Year)
```

```
[1] "numeric"
```

```
mode(data_18_KG$Year)
```

```
[1] "numeric"
```

```r
# try again

my_test_join <- full_join(data_22_KG, data_22_KZ)
```

```
Joining with `by = join_by(MM1, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9,
MM10, MM11, MM12, MM13, MM14, A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d, A4e,
A4f, A5a, A5b, A5c, A5d, A6, A7, B1, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b, B6c,
B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, B10, B11a, B11b, B12, B13, B14, B15a,
B15b, B15c, B15d, B16, D1, D2a, D2b, E1a, E1b, E1c, E1d, E1e, E2a, E2b, E2c,
E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a, E7b, E7c, E8a, E8b, E8c,
E8d, E8e, E9a, E9b, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17, E19a,
E19b, E19c, E20a, E20b, E20c, E21, G1a, G1b, G2, G3a, G3b, G4, G5, G6, G7, H1,
H2, H3, H4, H5a, H5b, DD1, DD2, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7a, DD7b,
DD7c, DD8, DD9a, DD9b, DD9c, DD9d, DD10, DD11, DD12, DD13, DD14, DD15, DD16,
DD17, DD18a, DD18b, DD19, DD20, EthnicGrp, AgeGrp, FinalWgt1, FinalWgt2,
Country)`
```

```r
# works now

data_22_KG <- data_22_KG |> rename('Year'='MM8')
data_22_KZ <- data_22_KZ |> rename('Year'='MM8')
data_22_UZ <- data_22_UZ |> rename('Year'='MM8')
```

8 Обработка данных

8.1 Выбор переменных

Мы могли бы объединить и работать со всей группой наборов данных, соединив 9 файлов, охватывающих 3 года и 3 страны. Тогда у нас был бы доступ ко всем переменным. Но это, вероятно, потребует много работы для обеспечения совместимости. Возможно, это было бы полезно для долгосрочного проекта, но мы пока просто экспериментируем.

Итак, чтобы рассмотреть ситуацию в меньшем масштабе, давайте сначала выберем интересующие нас переменные. Мы предварительно очистим их и проверим на совместимость. Затем объединим эти меньшие выборки, чтобы сделать результаты более понятными и удобными для просмотра.

Сначала мы рассмотрим меньший опрос 2018 года, чтобы попытаться выделить сопоставимые показатели за все годы. Сами вопросы, их обозначения и названия со временем меняются.

В 2018 году интересным вопросом был «в какой валюте вы храните свои сбережения?» (DD9d), но, к сожалению, этот вопрос не был включен в опросы 2020 и 2022 годов.

В итоге мы довольно подробно изучаем анкеты, но серьезный исследователь, работающий в долгосрочной перспективе, сделает это еще больше, пытаясь выделить

наиболее совместимые и стабильные данные за разные периоды времени и по разным странам.

Еще один интересный вопрос — это процент дохода, который домохозяйство получает от денежных переводов (DD9a). Хотя этот вопрос не задавался в 2020 году, мы учтем его для сравнения данных за 2018 и 2022 годы.

Другие стандартные переменные: пол (DD1), возраст (DD2), семейное положение (DD3), образование (DD4) и статус занятости (DD6a).

Есть вопросы о том, насколько положительно жители страны относятся к следующим странам: Китаю (E1a), России (E1b) и США (E1c).

Также есть вопросы об уровне доверия к следующим источникам новостей: телевидение (A2a), газеты (A2b), радио (A2c). Однако этот вопрос не повторяется в последующих волнах опроса, поэтому мы используем информацию об «Основном источнике новостей» (A1a).

Еще одна полезная демографическая переменная — язык, на котором говорят дома. Эта переменная кодируется как DD11 в 2018 и 2022 годах, но как DD9 в 2020 году. Это тот тип небольших исправлений, которые мы должны провести при очистке данных.

Чтобы оценить настроения, мы рассмотрим, улучшается или ухудшается финансовое положение страны (B4a, или B2 в 2018 году) по сравнению с улучшением или ухудшением положения отдельной семьи (B4b, или B5a в 2018 году).

Наконец, мы зафиксируем вопрос о том, движется ли страна в правильном или неправильном направлении (D1).

Нам также необходимо включить переменные «Страна» и «Год».

Мой окончательный список выбранных переменных

DD1 Пол

DD2 Возраст

DD3 Семейное положение

DD4 Образование

DD6a Занятость

D1 Направление (Правильное или Неправильное)

E1a Благосклонность Китая E1b Благосклонность России E1c Благосклонность США

DD9a Денежные переводы (Денежные переводы в 2018, 2022 годах)

A1a Основные новости (Источник)

DD11 Язык (родной) DD9 в 2020 году

B4a Финансовое положение страны (B2 в 2018 году)

B4b Финансовое положение семьи (B5a в 2018 году)

плюс сохранить страну, год

Сначала мы объединим файлы данных с помощью *full_join*, чтобы у нас был один многострановый файл для каждого года. Мы обнаружили еще одну небольшую проблему с узбекской переменной HHLandlines за 2018 год, которую необходимо переформатировать для обеспечения согласованности с другими. Типичная процедура очистки данных!

```
mydata2022 <- full_join(data_22_KG, data_22_KZ)
```

```
Joining with `by = join_by(MM1, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, Year,
MM9, MM10, MM11, MM12, MM13, MM14, A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d,
A4e, A4f, A5a, A5b, A5c, A5d, A6, A7, B1, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b,
B6c, B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, B10, B11a, B11b, B12, B13, B14,
B15a, B15b, B15c, B15d, B16, D1, D2a, D2b, E1a, E1b, E1c, E1d, E1e, E2a, E2b,
E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a, E7b, E7c, E8a, E8b,
E8c, E8d, E8e, E9a, E9b, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17,
E19a, E19b, E19c, E20a, E20b, E20c, E21, G1a, G1b, G2, G3a, G3b, G4, G5, G6,
G7, H1, H2, H3, H4, H5a, H5b, DD1, DD2, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7a,
DD7b, DD7c, DD8, DD9a, DD9b, DD9c, DD9d, DD10, DD11, DD12, DD13, DD14, DD15,
DD16, DD17, DD18a, DD18b, DD19, DD20, EthnicGrp, AgeGrp, FinalWgt1, FinalWgt2,
Country)`
```

```
mydata2022 <- full_join(mydata2022, data_22_UZ)
```

```
Joining with `by = join_by(MM1, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, Year,
MM9, MM10, MM11, MM12, MM13, MM14, A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, A4d,
A4e, A4f, A5a, A5b, A5c, A5d, A6, A7, B1, B2, B3, B4a, B4b, B5a, B5b, B6a, B6b,
B6c, B6d, B6e, B7, B8, B9a, B9b, B9c, B9d, B10, B11a, B11b, B12, B13, B14,
B15a, B15b, B15c, B15d, B16, D1, D2a, D2b, E1a, E1b, E1c, E1d, E1e, E2a, E2b,
E2c, E2d, E2e, E3, E4a, E4b, E5a, E5b, E5c, E6a, E6b, E7a, E7b, E7c, E8a, E8b,
E8c, E8d, E8e, E9a, E9b, E10, E11, E12, E13, E14, E15a, E15b, E15c, E16, E17,
E19a, E19b, E19c, E20a, E20b, E20c, E21, G1a, G1b, G2, G3a, G3b, G4, G5, G6,
G7, G8, G9, H1, H2, H3, H4, H5a, H5b, DD1, DD2, DD3, DD4, DD5, DD6a, DD6b,
DD6c, DD7a, DD7b, DD7c, DD8, DD9a, DD9b, DD9c, DD9d, DD10, DD11, DD12, DD13,
DD14, DD15, DD16, DD17, DD18a, DD18b, DD19, DD20, EthnicGrp, AgeGrp, FinalWgt1,
FinalWgt2, Country)`
```

```
mydata2020 <- full_join(data_20_KG, data_20_KZ)
```

```
Joining with `by = join_by(MM1, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9,
MM10, MM11, A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, B1, B2, B3, B4a, B4b, B5a,
B5b, B6a, B6b, B6c, B6d, B6e, B7, B8a, B8b, B8c, B8d, B9, I1, I2, I3, I4, I5a,
I5b, I5c, I5d, I6, I7a, I7b, I7c, I7d, I7e, D1, D2, E1a, E1b, E1c, E1d, E2a,
E2b, E2c, E2d, E3a, E3b, E3c, E4a, E4b, E4c, E5a, E5b, E5c, E6a, E6b, E7a, E7b,
E7c, G1a, G1b, G2, G3, G4, DD1, DD2, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7, DD8,
DD9, DD10, DD11, DD12, MM12, MM13, MM14, DD13, DD14, DD15, DD16a, DD16b, DD17,
DD18, AgeGrp, EthnicGrp, FinalWgt1, FinalWgt2, Country)`
```

```
mydata2020 <- full_join(mydata2020, data_20_UZ)
```

```
Joining with `by = join_by(MM1, MM2b, MM3a, MM3b, MM4, MM5, MM6, MM7, MM8, MM9,
MM10, MM11, A1a, A1b, A2, A3a, A3b, A4a, A4b, A4c, B1, B2, B3, B4a, B4b, B5a,
B5b, B6a, B6b, B6c, B6d, B6e, B7, B8a, B8b, B8c, B8d, B9, I1, I2, I3, I4, I5a,
I5b, I5c, I5d, I6, I7a, I7b, I7c, I7d, I7e, D1, D2, E1a, E1b, E1c, E1d, E2a,
E2b, E2c, E2d, E3a, E3b, E3c, E4a, E4b, E4c, E5a, E5b, E5c, E6a, E6b, E7a, E7b,
E7c, G1a, G1b, G2, G3, G4, DD1, DD2, DD3, DD4, DD5, DD6a, DD6b, DD6c, DD7, DD8,
DD9, DD10, DD11, DD12, MM12, MM13, MM14, DD13, DD14, DD15, DD16a, DD16b, DD17,
DD18, AgeGrp, EthnicGrp, FinalWgt1, FinalWgt2, Country)`
```

```
mydata2018 <- full_join(data_18_KG, data_18_KZ)
```

```
Joining with `by = join_by(IDNO, Wave, Country, Month, Day, Year, GeoCode,
IntCode, GendInt, SupvCode, Visit, IntBegin, IntEnd, Length, SamPt, NetComp,
NetPhone, Gender, Age, Church, Pray5x, Fast, Work, Occ, Income, IncomeOut,
Homelang, Water, Food, Housing, Electric, Educate, MedCare, Language, PeopPres,
Interact, Comphend, UnEz, BackChk, Method, Format, ThreatHi, Mosque, CelPhon,
OwnPC, Ethnic_M, Region_M, MainNews_M, Topprob_M, TrustGov_M, TrustUS_M,
HrsWorkGrp, AgeGrp, NetSocial, NetChat, Ssite_M, Lastyear_M, nextyear_M,
Statements1, Statements3, CommProb2, OpinionChina, OpinionRussia, OpinionUSA,
OpinionKAZ, OpinionKYR, OpinionTAJ, OpinionUzbek, PMSagintayev, HHLandlines,
NmbrMobilePhones, EighteenPlusMobile, MobileVsLandline, TrustRs_M, LiveHH18,
LLNumber, MobileNumber, HrsWork_M, CanBuy_M, Identfy_M, Religion_M,
ServiceProvider_M, TrustTV, TrustNwsPpr, TrustRad, MostTrust, HaveSatTV,
OpinionTurkey, MarriageStat2, HoH, Occ2, HoHJob, HoHOcc2, PartB4,
FutureSurveys, EducLevel_M, totwt, WatchRoss1, WatchEurAmTV, WatchSputnik,
WatchKhabar, WatchKTK, WatchOTRK, WatchCh5, WatchToj1, WatchSafina, WatchJah,
WatchSMT, WatchRSD, WatchVatan, WatchOzbek, WatchOzbek24, TrustRoss1,
TrustEurAmTV, TrustSputnik, TrustKhabar, TrustKTK, TrustOTRK, TrustCh5,
TrustToj1, TrustSafina, TrustJah, TrustSMT, TrustRSD, TrustOzbek, TrustOzbek24,
MediaEngInfo, GovtCntrlMedia, JournalReport, FairMedia, ForgnInflMedia, TVTime,
NetDomNews, NetIntlNews, Ssite2, SMDomNews, SMIntlNews, SMPoliticians,
SMFrdFam, SMGroups, EEUBenefit, HighPrices, CostFood, CostElect, CostBus,
CostHouse, Statements5, LastYrRemit, LLCalls, MobCalls, ServiceProvider2,
TypeOcc_M, HoHTypeOcc_M, WatchAA, WatchTV4, WatchOvaz, WatchNeit, WatchTurkPM,
OwnCar, AccessFood, OpinionTurkm, EconRelChina, EconRelRus, EconRelUS,
PMAbylgaziev, PlcHld, AgeGroup2, WhyRight1_M, WhyRight2_M, WhyWrong1_M,
WhyWrong2_M, WhyOpRus1_M, WhyOpRus2_M, WhyOpUS1_M, WhyOpUS2_M, BankAcc_M,
KeepMoney_M, MainIntNews_M, TVType_M, EconNY_M, BuyFood_M, RiteRong_M,
Improve1_M, Improve2_M, ChinaEng_M, ChinaEngWor_M, Party_M, TodayEcSit_M)`
```

```
# mydata2018 <- full_join(mydata2018, data_18_UZ)

# a problem with $$HHLandlines in last line
data_18_UZ$HHLandlines <- as.character(data_18_UZ$HHLandlines)
mydata2018 <- full_join(mydata2018, data_18_UZ)
```

```
Joining with `by = join_by(IDNO, Wave, Country, Month, Day, Year, GeoCode,
IntCode, GendInt, SupvCode, Visit, IntBegin, IntEnd, Length, SamPt, NetComp,
```

```
NetPhone, Gender, Age, Church, Pray5x, Fast, Work, Occ, Income, IncomeOut,
Homelang, Water, Food, Housing, Electric, Educate, MedCare, Language, PeopPres,
Interact, Comphend, UnEz, BackChk, Method, Format, ThreatHi, Mosque, CelPhon,
OwnPC, Ethnic_M, Region_M, MainNews_M, Topprob_M, TrustGov_M, TrustUS_M,
HrsWorkGrp, AgeGrp, NetSocial, NetChat, Ssite_M, Lastyear_M, nextyear_M,
Statements1, Statements3, CommProb2, OpinionChina, OpinionRussia, OpinionUSA,
OpinionKAZ, OpinionKYR, OpinionTAJ, OpinionUzbek, PMSagintayev, HHLandlines,
NmbrMobilePhones, EighteenPlusMobile, MobileVsLandline, TrustRs_M, LiveHH18,
LLNumber, MobileNumber, HrsWork_M, CanBuy_M, Identfy_M, Religion_M,
ServiceProvider_M, TrustTV, TrustNwsPpr, TrustRad, MostTrust, HaveSatTV,
OpinionTurkey, MarriageStat2, HoH, Occ2, HoHJob, HoHOcc2, PartB4,
FutureSurveys, EducLevel_M, totwt, WatchRoss1, WatchEurAmTV, WatchSputnik,
WatchKhabar, WatchKTK, WatchOTRK, WatchCh5, WatchToj1, WatchSafina, WatchJah,
WatchSMT, WatchRSD, WatchVatan, WatchOzbek, WatchOzbek24, TrustRoss1,
TrustEurAmTV, TrustSputnik, TrustKhabar, TrustKTK, TrustOTRK, TrustCh5,
TrustToj1, TrustSafina, TrustJah, TrustSMT, TrustRSD, TrustOzbek, TrustOzbek24,
MediaEngInfo, GovtCntrlMedia, JournalReport, FairMedia, ForgnInflMedia, TVTime,
NetDomNews, NetIntlNews, Ssite2, SMDomNews, SMIntlNews, SMPoliticians,
SMFrdFam, SMGroups, EEUBenefit, HighPrices, CostFood, CostElect, CostBus,
CostHouse, Statements5, LastYrRemit, LLCalls, MobCalls, ServiceProvider2,
TypeOcc_M, HoHTypeOcc_M, WatchAA, WatchTV4, WatchOvaz, WatchNeit, WatchTurkPM,
OwnCar, AccessFood, OpinionTurkm, EconRelChina, EconRelRus, EconRelUS,
PMAbylgaziev, PlcHld, AgeGroup2, WhyRight1_M, WhyRight2_M, WhyWrong1_M,
WhyWrong2_M, WhyOpRus1_M, WhyOpRus2_M, WhyOpUS1_M, WhyOpUS2_M, BankAcc_M,
KeepMoney_M, MainIntNews_M, TVType_M, EconNY_M, BuyFood_M, RiteRong_M,
Improve1_M, Improve2_M, ChinaEng_M, ChinaEngWor_M, Party_M, TodayEcSit_M)`
```

Проверьте имена, а затем переименуйте их в более понятные текстовые названия. Затем выберите список интересующих вас переменных. В приведенном ниже коде есть несколько дополнительных нюансов, обусловленных особенностями данных. Особенно неожиданны некоторые особенности именования в данных за 2018 год, поскольку там уже используются текстовые названия, просто по-другому и без документации!

```
names(mydata2018)
```

```
 [1] "IDNO"          "Wave"          "Country"
 [4] "Month"         "Day"           "Year"
 [7] "GeoCode"       "IntCode"       "GendInt"
[10] "SupvCode"      "Visit"         "IntBegin"
[13] "IntEnd"        "Length"        "SamPt"
[16] "NetComp"       "NetPhone"      "Gender"
[19] "Age"           "Church"        "Pray5x"
[22] "Fast"          "Work"          "Occ"
[25] "Income"        "IncomeOut"     "Homelang"
[28] "Water"         "Food"          "Housing"
[31] "Electric"      "Educate"       "MedCare"
[34] "Language"      "PeopPres"      "Interact"
[37] "Comphend"      "UnEz"          "BackChk"
```

```
 [40] "Method"             "Format"             "ThreatHi"
 [43] "Mosque"             "CelPhon"            "OwnPC"
 [46] "Ethnic_M"           "Region_M"           "MainNews_M"
 [49] "Topprob_M"          "TrustGov_M"         "TrustUS_M"
 [52] "HrsWorkGrp"         "AgeGrp"             "NetSocial"
 [55] "NetChat"            "Ssite_M"            "Lastyear_M"
 [58] "nextyear_M"         "Statements1"        "Statements3"
 [61] "CommProb2"          "OpinionChina"       "OpinionRussia"
 [64] "OpinionUSA"         "OpinionKAZ"         "OpinionKYR"
 [67] "OpinionTAJ"         "OpinionUzbek"       "PMSagintayev"
 [70] "HHLandlines"        "NmbrMobilePhones"   "EighteenPlusMobile"
 [73] "MobileVsLandline"   "TrustRs_M"          "LiveHH18"
 [76] "LLNumber"           "MobileNumber"       "HrsWork_M"
 [79] "CanBuy_M"           "Identfy_M"          "Religion_M"
 [82] "ServiceProvider_M"  "TrustTV"            "TrustNwsPpr"
 [85] "TrustRad"           "MostTrust"          "HaveSatTV"
 [88] "OpinionTurkey"      "MarriageStat2"      "HoH"
 [91] "Occ2"               "HoHJob"             "HoHOcc2"
 [94] "PartB4"             "FutureSurveys"      "EducLevel_M"
 [97] "totwt"              "WatchRoss1"         "WatchEurAmTV"
[100] "WatchSputnik"       "WatchKhabar"        "WatchKTK"
[103] "WatchOTRK"          "WatchCh5"           "WatchToj1"
[106] "WatchSafina"        "WatchJah"           "WatchSMT"
[109] "WatchRSD"           "WatchVatan"         "WatchOzbek"
[112] "WatchOzbek24"       "TrustRoss1"         "TrustEurAmTV"
[115] "TrustSputnik"       "TrustKhabar"        "TrustKTK"
[118] "TrustOTRK"          "TrustCh5"           "TrustToj1"
[121] "TrustSafina"        "TrustJah"           "TrustSMT"
[124] "TrustRSD"           "TrustOzbek"         "TrustOzbek24"
[127] "MediaEngInfo"       "GovtCntrlMedia"     "JournalReport"
[130] "FairMedia"          "ForgnInflMedia"     "TVTime"
[133] "NetDomNews"         "NetIntlNews"        "Ssite2"
[136] "SMDomNews"          "SMIntlNews"         "SMPoliticians"
[139] "SMFrdFam"           "SMGroups"           "EEUBenefit"
[142] "HighPrices"         "CostFood"           "CostElect"
[145] "CostBus"            "CostHouse"          "Statements5"
[148] "LastYrRemit"        "LLCalls"            "MobCalls"
[151] "ServiceProvider2"   "TypeOcc_M"          "HoHTypeOcc_M"
[154] "WatchAA"            "WatchTV4"           "WatchOvaz"
[157] "WatchNeit"          "WatchTurkPM"        "OwnCar"
[160] "AccessFood"         "OpinionTurkm"       "EconRelChina"
[163] "EconRelRus"         "EconRelUS"          "PMAbylgaziev"
[166] "PlcHld"             "AgeGroup2"          "WhyRight1_M"
[169] "WhyRight2_M"        "WhyWrong1_M"        "WhyWrong2_M"
[172] "WhyOpRus1_M"        "WhyOpRus2_M"        "WhyOpUS1_M"
[175] "WhyOpUS2_M"         "BankAcc_M"          "KeepMoney_M"
[178] "MainIntNews_M"      "TVType_M"           "EconNY_M"
[181] "BuyFood_M"          "RiteRong_M"         "Improve1_M"
```

```
[184] "Improve2_M"         "ChinaEng_M"         "ChinaEngWor_M"
[187] "Party_M"            "TodayEcSit_M"
```

```r
names(mydata2020)
```

```
  [1] "MM1"       "MM2b"      "MM3a"      "MM3b"      "MM4"       "MM5"
  [7] "MM6"       "MM7"       "MM8"       "MM9"       "MM10"      "MM11"
 [13] "A1a"       "A1b"       "A2"        "A3a"       "A3b"       "A4a"
 [19] "A4b"       "A4c"       "B1"        "B2"        "B3"        "B4a"
 [25] "B4b"       "B5a"       "B5b"       "B6a"       "B6b"       "B6c"
 [31] "B6d"       "B6e"       "B7"        "B8a"       "B8b"       "B8c"
 [37] "B8d"       "B9"        "I1"        "I2"        "I3"        "I4"
 [43] "I5a"       "I5b"       "I5c"       "I5d"       "I6"        "I7a"
 [49] "I7b"       "I7c"       "I7d"       "I7e"       "D1"        "D2"
 [55] "E1a"       "E1b"       "E1c"       "E1d"       "E2a"       "E2b"
 [61] "E2c"       "E2d"       "E3a"       "E3b"       "E3c"       "E4a"
 [67] "E4b"       "E4c"       "E5a"       "E5b"       "E5c"       "E6a"
 [73] "E6b"       "E7a"       "E7b"       "E7c"       "G1a"       "G1b"
 [79] "G2"        "G3"        "G4"        "DD1"       "DD2"       "DD3"
 [85] "DD4"       "DD5"       "DD6a"      "DD6b"      "DD6c"      "DD7"
 [91] "DD8"       "DD9"       "DD10"      "DD11"      "DD12"      "MM12"
 [97] "MM13"      "MM14"      "DD13"      "DD14"      "DD15"      "DD16a"
[103] "DD16b"     "DD17"      "DD18"      "AgeGrp"    "EthnicGrp" "FinalWgt1"
[109] "FinalWgt2" "Country"
```

```r
names(mydata2022)
```

```
  [1] "MM1"       "MM2b"      "MM3a"      "MM3b"      "MM4"       "MM5"
  [7] "MM6"       "MM7"       "Year"      "MM9"       "MM10"      "MM11"
 [13] "MM12"      "MM13"      "MM14"      "A1a"       "A1b"       "A2"
 [19] "A3a"       "A3b"       "A4a"       "A4b"       "A4c"       "A4d"
 [25] "A4e"       "A4f"       "A5a"       "A5b"       "A5c"       "A5d"
 [31] "A6"        "A7"        "B1"        "B2"        "B3"        "B4a"
 [37] "B4b"       "B5a"       "B5b"       "B6a"       "B6b"       "B6c"
 [43] "B6d"       "B6e"       "B7"        "B8"        "B9a"       "B9b"
 [49] "B9c"       "B9d"       "B10"       "B11a"      "B11b"      "B12"
 [55] "B13"       "B14"       "B15a"      "B15b"      "B15c"      "B15d"
 [61] "B16"       "D1"        "D2a"       "D2b"       "E1a"       "E1b"
 [67] "E1c"       "E1d"       "E1e"       "E2a"       "E2b"       "E2c"
 [73] "E2d"       "E2e"       "E3"        "E4a"       "E4b"       "E5a"
 [79] "E5b"       "E5c"       "E6a"       "E6b"       "E7a"       "E7b"
 [85] "E7c"       "E8a"       "E8b"       "E8c"       "E8d"       "E8e"
 [91] "E9a"       "E9b"       "E10"       "E11"       "E12"       "E13"
 [97] "E14"       "E15a"      "E15b"      "E15c"      "E16"       "E17"
[103] "E19a"      "E19b"      "E19c"      "E20a"      "E20b"      "E20c"
[109] "E21"       "G1a"       "G1b"       "G2"        "G3a"       "G3b"
[115] "G4"        "G5"        "G6"        "G7"        "G8"        "G9"
[121] "H1"        "H2"        "H3"        "H4"        "H5a"       "H5b"
```

```
[127] "DD1"       "DD2"       "DD3"       "DD4"       "DD5"       "DD6a"
[133] "DD6b"      "DD6c"      "DD7a"      "DD7b"      "DD7c"      "DD8"
[139] "DD9a"      "DD9b"      "DD9c"      "DD9d"      "DD10"      "DD11"
[145] "DD12"      "DD13"      "DD14"      "DD15"      "DD16"      "DD17"
[151] "DD18a"     "DD18b"     "DD19"      "DD20"      "EthnicGrp" "AgeGrp"
[157] "FinalWgt1" "FinalWgt2" "Country"   "MM1a"      "G8_1"      "G9_1"
[163] "G8_2"      "G9_2"
```

```
mydata2022 <- mydata2022 |> rename('Sex'='DD1', 'Age'='DD2', 'Marital'='DD3',
                                   'Education'='DD4', 'Employment'='DD6a',
                                   'Direction'='D1', 'China_Favor'='E1a',
                                   'Russia_Favor'='E1b','USA_Favor'='E1c',
                                   'Main_News'='A1a', 'Remit'='DD9a',
                                   'Language'='DD11','Country_Fin_Sit'='B4a',
                                   'Family_Fin_Sit'='B4b')

mydata2022_select <- mydata2022 |> select('Sex', 'Age', 'Marital',
 ↪  'Education',
                                          'Employment', 'Direction',
                                           ↪  'China_Favor',
                                          'Russia_Favor','USA_Favor',
                                           ↪  'Main_News',
                                          'Remit',
                                           ↪  'Language','Country_Fin_Sit',
                                          'Family_Fin_Sit', 'Country',
                                           ↪  'Year')

# note we rename Year here from MM8

mydata2020 <- mydata2020 |> rename('Sex'='DD1', 'Age'='DD2', 'Marital'='DD3',
                                   'Education'='DD4', 'Employment'='DD6a',
                                   'Direction'='D1', 'China_Favor'='E1a',
                                   'Russia_Favor'='E1b','USA_Favor'='E1c',
                                   'Main_News'='A1a', 'Language'='DD9',
                                   'Country_Fin_Sit'='B4a',
                                    ↪  'Family_Fin_Sit'='B4b',
                                   'Year'='MM8')

mydata2020_select <- mydata2020 |> select('Sex', 'Age', 'Marital',
 ↪  'Education',
                                          'Employment', 'Direction',
                                           ↪  'China_Favor',
                                          'Russia_Favor','USA_Favor',
                                           ↪  'Main_News',
                                          'Language','Country_Fin_Sit',
                                          'Family_Fin_Sit', 'Country',
                                           ↪  'Year')

# need to add a blank 'Remit' variable here
```

```
mydata2020_select <- mydata2020_select |> mutate(Remit=NA)

# and 2018 data already uses the names, but formatted differently
# codebook is not satisfactory, does not describe these labels, have to judge
 ↪  by answers in some cases
# note the 'LangExtra' to avoid repeating a name

mydata2018 <- mydata2018 |> rename('Sex'='Gender', 'Marital'='MarriageStat2',
                                   'Education'='EducLevel_M',
                                    ↪  'Employment'='Work',
                                   'Direction'='RiteRong_M',
                                    ↪  'China_Favor'='OpinionChina',

                                    ↪  'Russia_Favor'='OpinionRussia','USA_Favor'='OpinionUSA'
                                   'Main_News'='MainNews_M',
                                    ↪  'Language'='Homelang','LangExtra'='Language',
                                   'Country_Fin_Sit'='TodayEcSit_M',
                                    ↪  'Family_Fin_Sit'='Lastyear_M',
                                   'Remit'='IncomeOut')

mydata2018_select <- mydata2018 |> select('Sex', 'Age', 'Marital',
 ↪  'Education',
                                          'Employment', 'Direction',
                                           ↪  'China_Favor',
                                          'Russia_Favor','USA_Favor',
                                           ↪  'Main_News',
                                          'Language','Country_Fin_Sit',
                                           ↪  'Remit',
                                          'Family_Fin_Sit', 'Country',
                                           ↪  'Year')
```

Мы могли бы попробовать выполнить больше полных объединений, но поскольку мы уже вручную изменили имена переменных, чтобы они были согласованы для всех трех лет, здесь мы можем просто выполнить прямое объединение трех файлов с помощью *rbind*, а затем еще раз проверить, что все получилось так, как ожидалось.

```
my_final_data <- rbind(mydata2018_select, mydata2020_select,
 ↪  mydata2022_select)
str(my_final_data)
```

```
tibble [15,029 x 16] (S3: tbl_df/tbl/data.frame)
 $ Sex            : chr [1:15029] "Female" "Female" "Female" "Female" ...
 $ Age            : num [1:15029] 29 83 48 37 43 60 34 42 18 55 ...
 $ Marital        : chr [1:15029] "Single" "Widowed or divorced" "Single" "Married" ...
 $ Education      : chr [1:15029] "Complete higher education" "Complete higher education" "Voc
 $ Employment     : chr [1:15029] "Unemployed and actively seeking employment" "Retired" "Unem
time" ...
 $ Direction      : chr [1:15029] "Right direction" "Wrong direction" "Don't Know (vol.)" "Wro
```

```
 $ China_Favor    : chr [1:15029] "Very Unfavorable" "Somewhat Favorable" "Somewhat Favorable"
 $ Russia_Favor   : chr [1:15029] "Very Favorable" "Very Favorable" "Somewhat Favorable" "Don'
 $ USA_Favor      : chr [1:15029] "Somewhat Unfavorable" "Don't Know (vol.)" "Somewhat Unfavor
 $ Main_News      : chr [1:15029] "Internet" "Russian television stations" "Russian television
 $ Language       : chr [1:15029] "Russian" "Russian" "Russian" "Russian" ...
 $ Country_Fin_Sit: chr [1:15029] "About the Same" "About the Same" "Don't Know (vol.)" "About
 $ Remit          : chr [1:15029] "Not Applicable / No Relatives Abroad / No Remittances from
 $ Family_Fin_Sit : chr [1:15029] "Become Worse" "Become Worse" "Become Worse" "Stayed the Sam
 $ Country        : chr [1:15029] "Kyrgyzstan" "Kyrgyzstan" "Kyrgyzstan" "Kyrgyzstan" ...
 $ Year           : num [1:15029] 2018 2018 2018 2018 2018 ...
```

```r
summary(my_final_data)
```

```
     Sex                 Age          Marital           Education
 Length:15029       Min.   :18.00   Length:15029       Length:15029
 Class :character   1st Qu.:27.00   Class :character   Class :character
 Mode  :character   Median :35.00   Mode  :character   Mode  :character
                    Mean   :37.92
                    3rd Qu.:47.00
                    Max.   :98.00
  Employment         Direction         China_Favor        Russia_Favor
 Length:15029       Length:15029       Length:15029       Length:15029
 Class :character   Class :character   Class :character   Class :character
 Mode  :character   Mode  :character   Mode  :character   Mode  :character



  USA_Favor          Main_News           Language         Country_Fin_Sit
 Length:15029       Length:15029       Length:15029       Length:15029
 Class :character   Class :character   Class :character   Class :character
 Mode  :character   Mode  :character   Mode  :character   Mode  :character



    Remit           Family_Fin_Sit       Country               Year
 Length:15029       Length:15029       Length:15029       Min.   :2018
 Class :character   Class :character   Class :character   1st Qu.:2018
 Mode  :character   Mode  :character   Mode  :character   Median :2020
                                                           Mean   :2020
                                                           3rd Qu.:2022
                                                           Max.   :2022
```

```r
attach(my_final_data)
```

8.2 Описательная статистика

Давайте рассмотрим несколько из этих переменных и посмотрим, как они распределены. Простая команда *table* поможет вам получить первоначальное представление о данных.

Хотя некоторые большие наборы данных сложно интуитивно понять, для такого рода данных в социальных науках ничто не сравнится с тем, чтобы потратить время на изучение данных, прежде чем переходить к более сложному анализу. Мы также можем обнаружить выбросы или проблемы, которые необходимо исправить, прежде чем двигаться дальше. Мы обнаруживаем проблему с переменной «Денежный перевод» (Remit), которую необходимо преобразовать в числовой формат.

Мы можем запустить любые перекрестные таблицы, перечислив две переменные в команде *table*. Можно исследовать множество комбинаций (здесь не показано).

```
table(Sex)
```

```
Sex
Female   Male
  7501   7528
```

```
table(Age)
```

```
Age
 18  19  20  21  22  23  24  25  26  27  28  29  30  31  32  33  34  35  36  37
431 314 406 349 373 353 376 501 386 499 465 391 669 379 530 418 366 473 372 356
 38  39  40  41  42  43  44  45  46  47  48  49  50  51  52  53  54  55  56  57
376 266 455 223 309 289 203 335 240 222 249 198 341 153 209 212 168 200 147 144
 58  59  60  61  62  63  64  65  66  67  68  69  70  71  72  73  74  75  76  77
170 119 242 128 113 139  89 123  65  56  49  45  89  33  41  34  15  21  17  13
 78  79  80  81  82  83  84  85  87  88  89  90  93  95  98
 14   8  19  10   7   4   4   3   2   2   1   1   1   1   5
```

```
table(Marital)
```

```
Marital
  Don't Know (vol.)             Married      Refused (vol.)              Single
                  9               10072                  53                3266
Widowed or divorced
               1629
```

```
table(Education)
```

```
Education
                            Complete higher education
                                                 3825
                                      Complete school
                                                 3161
Complete vocational - vocational school, lyceum, etc.
                                                 3176
                                   Don't Know (vol.)
                                                    4
                                      Finished school
```

```
                                                   1510
                          Incomplete higher education
                                                   1039
                                     Incomplete school
                                                    382
                      Incomplete vocational education
                                                    524
                                         No education
                                                     25
                                       Refused (vol.)
                                                     12
          Vocational (vocational school, lyceum etc.)
                                                   1371
```

```
table(Employment)
```

```
Employment
                                   A housewife
                                           961
                     A housewife / househusband
                                          1872
                                     A student
                                           809
                              Don't Know (vol.)
                                            20
                                Refused (vol.)
                                            23
                                       Retired
                                          1611
    Unemployed and actively seeking employment
                                          1193
Unemployed and not actively seeking employment
                                           668
                              Working full-time
                                          5842
                              Working part-time
                                          2030
```

```
table(Direction)
```

```
Direction
Don't Know (vol.)         Not asked    Refused (vol.)   Right direction
             1563              1500               223              9885
  Wrong direction
             1858
```

```
table(China_Favor)
```

```
China_Favor
   Don't Know (vol.)       Refused (vol.)   Somewhat Favorable
                1986                  161                 5736
Somewhat Unfavorable       Very Favorable     Very Unfavorable
                2739                 1811                 2596
```

```
table(Sex)
```

```
Sex
Female   Male
  7501   7528
```

```
table(Russia_Favor)
```

```
Russia_Favor
   Don't Know (vol.)       Refused (vol.)   Somewhat Favorable
                1116                  105                 7439
Somewhat Unfavorable       Very Favorable     Very Unfavorable
                1367                 4282                  720
```

```
table(USA_Favor)
```

```
USA_Favor
   Don't Know (vol.)       Refused (vol.)   Somewhat Favorable
                3213                  193                 4734
Somewhat Unfavorable       Very Favorable     Very Unfavorable
                2714                 2113                 2062
```

```
table(Main_News)
```

```
Main_News
                                 Don't Know (vol.)
                                               333
                      Family, friends, or neighbors
                                               313
                                          Internet
                                              5397
                            Internet: blogs, others
                                               614
                                        Local radio
                                                33
Non-government newspapers published in our country
                                                11
              None / Not interested in news (vol.)
                                               337
                                       Other (vol.)
                                                52
                         Other foreign news sources
```

```
                                                 11
                          Other television stations
                                                 11
         Our country's national television stations
                                               5526
                   Our government's newspapers
                                                 71
                                              Radio
                                                 40
                                    Refused (vol.)
                                                 23
                  Religious services or literature
                                                 10
                                Russian newspapers
                                                  5
                                      Russian radio
                                                 13
                       Russian television stations
                                               263
                  Social media sites or messengers
                                               1966
```

```
table(Country_Fin_Sit)
```

```
Country_Fin_Sit
   About the Same Don't Know (vol.)       Much Better        Much Worse
             2790               555              3292              1745
   Refused (vol.)   Somewhat Better    Somewhat Worse
               73              4188              2386
```

```
table(Remit)
```

```
Remit
                                                                    1
                                                                    6
                                                 1.00000000000000000
                                                                    4
                                                                   10
                                                                   64
                                                10.00000000000000000
                                                                   28
                                                                  100
                                                                  130
                                               100.00000000000000000
                                                                   29
                                                14.00000000000000000
                                                                    1
                                                                   15
```

17
15.00000000000000000
7
17
1
2
6
2.00000000000000000
4
20
60
20.00000000000000000
19
24.00000000000000000
1
25
7
25.00000000000000000
5
3
5
3.00000000000000000
3
30
80
30.00000000000000000
26
33
1
33.00000000000000000
1
35
4
35.00000000000000000
1
4
3
4.00000000000000000
3
40
41
40.00000000000000000
16
45
1
5
15
5.00000000000000000

14
50
218
50.00000000000000000
62
6.00000000000000000
1
60
33
60.00000000000000000
9
65.00000000000000000
1
7
2
70
84
70.00000000000000000
18
75
7
75.00000000000000000
1
8
1
8.00000000000000000
1
80
61
80.00000000000000000
12
85
5
9.00000000000000000
1
90
50
90.00000000000000000
15
95
2
95.00000000000000000
1
98
2
99
2
Don't Know (vol.)

```
                                                                    310
            Not Applicable / No Relatives Abroad / No Remittances from A
                                                                   3628
Not Applicable / No Relatives Abroad / No Remittances from Abroad (vol.)
                                                                   3745
                                                         Refused (vol.)
                                                                    154
```

```
# fix the problem with Remit

my_final_data$Remit<-as.numeric(Remit)
```

```
Warning: NAs introduced by coercion
```

```
attach(my_final_data)
```

```
The following objects are masked from my_final_data (pos = 3):

    Age, China_Favor, Country, Country_Fin_Sit, Direction, Education,
    Employment, Family_Fin_Sit, Language, Main_News, Marital, Remit,
    Russia_Favor, Sex, USA_Favor, Year
```

```
table(Remit)
```

```
Remit
  1   2   3   4   5   6   7   8   9  10  14  15  17  20  24  25  30  33  35  40
 10  10   8   6  29   1   2   2   1  92   1  24   1  79   1  12 106   2   5  57
 45  50  60  65  70  75  80  85  90  95  98  99 100
  1 280  42   1 102   8  73   5  65   3   2   2 159
```

```
table(Family_Fin_Sit)
```

```
Family_Fin_Sit
   About the same     Become Better      Become Worse Don't Know (vol.)
             3658              2446               453               148
      Much better       Much Better        Much worse        Much Worse
             1041               705               255               611
   Refused (vol.)   Somewhat better   Somewhat Better    Somewhat worse
               50              1371              1323               427
   Somewhat Worse   Stayed the Same
              987              1554
```

```
table(Country)
```

```
Country
Kazakhstan Kyrgyzstan Uzbekistan
      5011       5018       5000
```

```r
table(Year)
```

```
Year
2018 2019 2020 2022
4473   27 6000 4529
```

```r
table(Direction, Sex)
```

```
                   Sex
Direction           Female Male
  Don't Know (vol.)    883  680
  Not asked            629  871
  Refused (vol.)       101  122
  Right direction     4993 4892
  Wrong direction      895  963
```

```r
table(Marital, Employment)
```

```
                      Employment
Marital                A housewife A housewife / househusband A student
  Don't Know (vol.)              1                           1         0
  Married                      834                        1616        80
  Refused (vol.)                 5                           2         2
  Single                        54                         136       720
  Widowed or divorced           67                         117         7
                      Employment
Marital                Don't Know (vol.) Refused (vol.) Retired
  Don't Know (vol.)                    0              0       0
  Married                             16              7     988
  Refused (vol.)                       0             10       3
  Single                               2              5      65
  Widowed or divorced                  2              1     555
                      Employment
Marital                Unemployed and actively seeking employment
  Don't Know (vol.)                                             2
  Married                                                     777
  Refused (vol.)                                                4
  Single                                                      318
  Widowed or divorced                                          92
                      Employment
Marital                Unemployed and not actively seeking employment
  Don't Know (vol.)                                                  0
  Married                                                          446
  Refused (vol.)                                                     3
  Single                                                           175
  Widowed or divorced                                               44
                      Employment
Marital                Working full-time Working part-time
```

```
  Don't Know (vol.)                    4                 1
  Married                           3980              1328
  Refused (vol.)                      15                 9
  Single                            1299               492
  Widowed or divorced                544               200
```

```
table(Marital, Education)
```

```
                     Education
Marital               Complete higher education Complete school
  Don't Know (vol.)                           1               2
  Married                                  2765            2285
  Refused (vol.)                             22               2
  Single                                    645             564
  Widowed or divorced                       392             308
                     Education
Marital               Complete vocational - vocational school, lyceum, etc.
  Don't Know (vol.)                                                      1
  Married                                                             2114
  Refused (vol.)                                                         4
  Single                                                               767
  Widowed or divorced                                                  290
                     Education
Marital               Don't Know (vol.) Finished school
  Don't Know (vol.)                   1               1
  Married                             1            1101
  Refused (vol.)                      0               1
  Single                              1             177
  Widowed or divorced                 1             230
                     Education
Marital               Incomplete higher education Incomplete school
  Don't Know (vol.)                             0                 0
  Married                                     367               251
  Refused (vol.)                                3                 0
  Single                                      619                63
  Widowed or divorced                          50                68
                     Education
Marital               Incomplete vocational education No education
  Don't Know (vol.)                                 2            0
  Married                                         304           14
  Refused (vol.)                                    2            1
  Single                                          151            3
  Widowed or divorced                              65            7
                     Education
Marital               Refused (vol.)
  Don't Know (vol.)                0
  Married                          0
  Refused (vol.)                   9
```

```
  Single                            3
  Widowed or divorced               0
                     Education
Marital               Vocational (vocational school, lyceum etc.)
  Don't Know (vol.)                                             1
  Married                                                     870
  Refused (vol.)                                                9
  Single                                                      273
  Widowed or divorced                                         218
```

```
table(Education, Employment)
```

```
                                                     Employment
Education                                             A housewife
  Complete higher education                                   127
  Complete school                                               0
  Complete vocational - vocational school, lyceum, etc.         0
  Don't Know (vol.)                                             0
  Finished school                                             458
  Incomplete higher education                                  19
  Incomplete school                                            25
  Incomplete vocational education                              62
  No education                                                  0
  Refused (vol.)                                                0
  Vocational (vocational school, lyceum etc.)                 270
                                                     Employment
Education                                             A housewife / househusband
  Complete higher education                                                  327
  Complete school                                                            815
  Complete vocational - vocational school, lyceum, etc.                      541
  Don't Know (vol.)                                                            1
  Finished school                                                              0
  Incomplete higher education                                                 56
  Incomplete school                                                           77
  Incomplete vocational education                                             47
  No education                                                                 8
  Refused (vol.)                                                               0
  Vocational (vocational school, lyceum etc.)                                  0
                                                     Employment
Education                                             A student
  Complete higher education                                    22
  Complete school                                             107
  Complete vocational - vocational school, lyceum, etc.        76
  Don't Know (vol.)                                             0
  Finished school                                              43
  Incomplete higher education                                 440
  Incomplete school                                            13
  Incomplete vocational education                              85
```

No education	0
Refused (vol.)	0
Vocational (vocational school, lyceum etc.)	23

Education	Employment Don't Know (vol.)
Complete higher education	8
Complete school	6
Complete vocational - vocational school, lyceum, etc.	4
Don't Know (vol.)	1
Finished school	0
Incomplete higher education	1
Incomplete school	0
Incomplete vocational education	0
No education	0
Refused (vol.)	0
Vocational (vocational school, lyceum etc.)	0

Education	Employment Refused (vol.)	Retired
Complete higher education	4	355
Complete school	3	256
Complete vocational - vocational school, lyceum, etc.	0	238
Don't Know (vol.)	1	0
Finished school	3	322
Incomplete higher education	1	26
Incomplete school	1	80
Incomplete vocational education	0	68
No education	0	2
Refused (vol.)	8	0
Vocational (vocational school, lyceum etc.)	2	264

Education	Employment Unemployed and actively seeking employ
Complete higher education	
Complete school	
Complete vocational - vocational school, lyceum, etc.	
Don't Know (vol.)	
Finished school	
Incomplete higher education	
Incomplete school	
Incomplete vocational education	
No education	
Refused (vol.)	
Vocational (vocational school, lyceum etc.)	

Education	Employment Unemployed and not actively seeking em
Complete higher education	
Complete school	
Complete vocational - vocational school, lyceum, etc.	
Don't Know (vol.)	

```
  Finished school
  Incomplete higher education
  Incomplete school
  Incomplete vocational education
  No education
  Refused (vol.)
  Vocational (vocational school, lyceum etc.)
                                                        Employment
Education                                                Working full-time
  Complete higher education                                           2240
  Complete school                                                     1008
  Complete vocational - vocational school, lyceum, etc.               1351
  Don't Know (vol.)                                                      1
  Finished school                                                      269
  Incomplete higher education                                          275
  Incomplete school                                                     85
  Incomplete vocational education                                      133
  No education                                                           6
  Refused (vol.)                                                         1
  Vocational (vocational school, lyceum etc.)                          473
                                                        Employment
Education                                                Working part-time
  Complete higher education                                           435
  Complete school                                                     502
  Complete vocational - vocational school, lyceum, etc.               493
  Don't Know (vol.)                                                      0
  Finished school                                                      169
  Incomplete higher education                                          153
  Incomplete school                                                     53
  Incomplete vocational education                                       57
  No education                                                           2
  Refused (vol.)                                                         2
  Vocational (vocational school, lyceum etc.)                          164
```

8.3 Перекодирование

Мы заметили некоторые проблемы, которые также хотим исправить, чтобы упростить представление данных, например, перекодировать ответы, объединив их в одну метку «Не знаю» и «Отказано» (NA — недоступно). Это поможет нам сосредоточить визуализацию на значимых категориях.

Давайте также проведем более обширную перекодировку, чтобы упростить некоторые из многочисленных категорий полупротиворечивых ответов, которые мы здесь видим.

```
my_final_data$Marital_recode <- replace_values(
  Marital,
  c("Don't Know (vol.)", "Refused (vol.)") ~ NA
)
```

```r
my_final_data$Employment_recode <- replace_values(
  Employment,
  c("Don't Know (vol.)", "Refused (vol.)") ~ NA
)

my_final_data$Employment_recode2 <- replace_values(
  Employment,
  c("Working part-time", "Working full-time") ~ "Working",
  c("Unemployed and not actively seeking employment", "Unemployed and
   ↪  actively seeking employment") ~ "Unemployed",
  c("A housewife / househusband","A housewife") ~ "Housewife",
  c("Don't Know (vol.)", "Refused (vol.)") ~ NA
)

my_final_data$Direction_recode <- replace_values(
  Direction,
  c("Don't Know (vol.)", "Refused (vol.)", "Not asked") ~ NA
)

my_final_data$Family_Fin_Sit_recode <- replace_values(
  Family_Fin_Sit,
  c("Much better", "Much Better", "Become Better", "Somewhat better",
   ↪  "Somewhat Better") ~ "Better",
  c("About the same", "Stayed the Same") ~ "Same",
  c("Become Worse","Much Worse", "Much worse", "Somewhat Worse", "Somewhat
   ↪  worse") ~ "Worse",
  c("Don't Know (vol.)", "Refused (vol.)") ~ NA
)

attach(my_final_data)
```

```
The following objects are masked from my_final_data (pos = 3):

    Age, China_Favor, Country, Country_Fin_Sit, Direction, Education,
    Employment, Family_Fin_Sit, Language, Main_News, Marital, Remit,
    Russia_Favor, Sex, USA_Favor, Year


The following objects are masked from my_final_data (pos = 4):

    Age, China_Favor, Country, Country_Fin_Sit, Direction, Education,
    Employment, Family_Fin_Sit, Language, Main_News, Marital, Remit,
    Russia_Favor, Sex, USA_Favor, Year
```

```r
table(Marital_recode,Employment_recode)
```

```
                     Employment_recode
Marital_recode        A housewife A housewife / househusband A student Retired
```

```
  Married                     834                        1616        80     988
  Single                       54                         136       720      65
  Widowed or divorced          67                         117         7     555
                     Employment_recode
Marital_recode        Unemployed and actively seeking employment
  Married                                                    777
  Single                                                     318
  Widowed or divorced                                         92
                     Employment_recode
Marital_recode        Unemployed and not actively seeking employment
  Married                                                       446
  Single                                                        175
  Widowed or divorced                                            44
                     Employment_recode
Marital_recode        Working full-time Working part-time
  Married                          3980              1328
  Single                           1299               492
  Widowed or divorced               544               200
```

9 Критерий хи-квадрат

Когда у нас есть перекрестная таблица с несколькими элементами, критерий хи-квадрат может проверить, является ли частота встречаемости элементов в ячейках результатом случайного рассеяния или статистически значимой. Это указывает на наличие определенной закономерности или неслучайной связи в данных, не объясняя ее. Как и другие статистические инструменты в R, существует богатый набор опций и альтернатив для работы со статистическими тестами. Мы здесь даже не затрагиваем поверхность этих возможностей, но включаем это как напоминание о них.

```r
chisq.test(table(Direction,Sex))
```

```
    Pearson's Chi-squared test

data:  table(Direction, Sex)
X-squared = 70.858, df = 4, p-value = 1.496e-14
```

10 Визуализация данных

Теперь пришло время визуально проанализировать данные. Мы рассмотрим некоторые переменные, в частности, сосредоточимся на направлении развития страны. В данном случае речь идет о странах, поскольку мы включаем все три страны за все три года.

10.1 Диаграммы рассеяния

Начнём с диаграмм рассеяния. В наших данных переменная «Remit» как минимум одна подходит для диаграмм рассеяния. Большинство других переменных не подходят, поскольку являются категориальными.

```
plot(Remit~Year)
```

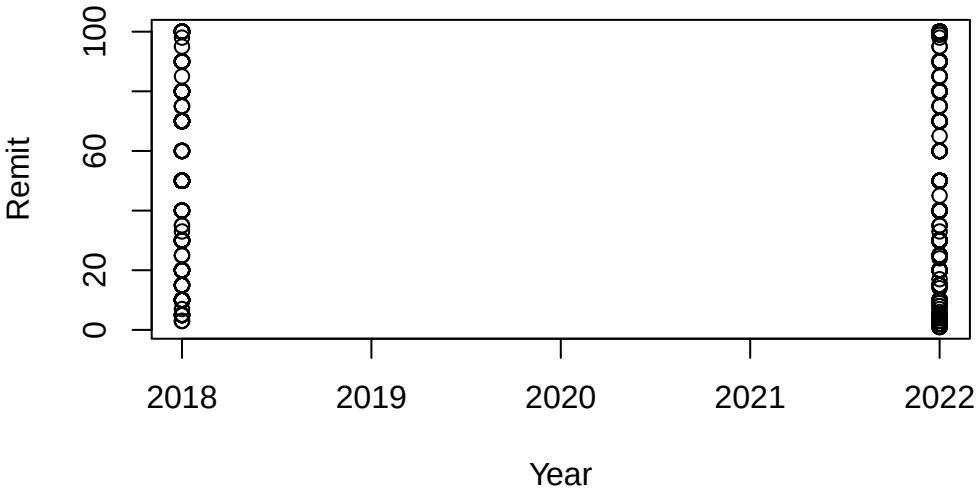

Не очень интересно, правда? Может, добавить линию регрессии? Всё равно не очень интересно.

```
plot(Remit~Year)
abline(lm(Remit~Year), col="red")
```

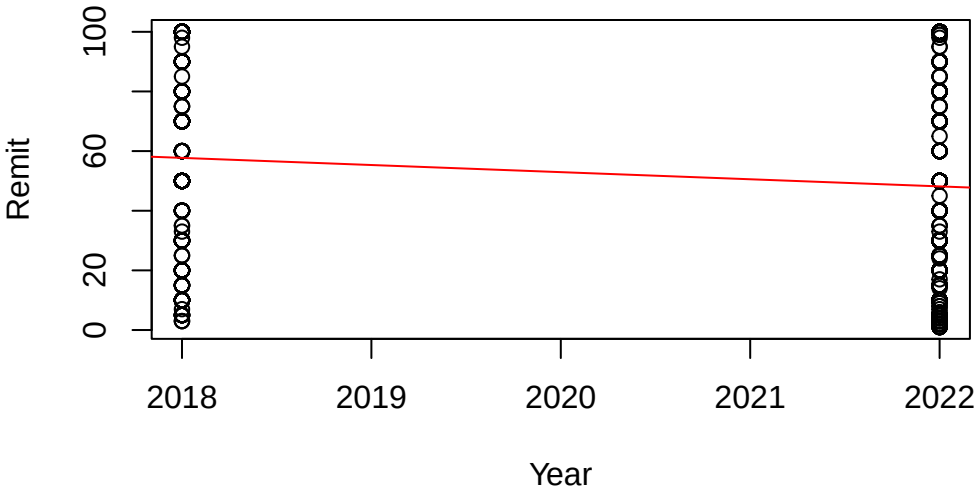

Давайте хотя бы выберем что-нибудь, на фоне чего можно строить планы, что будет хоть немного разнообразным.

```
plot(Remit~Age)
```

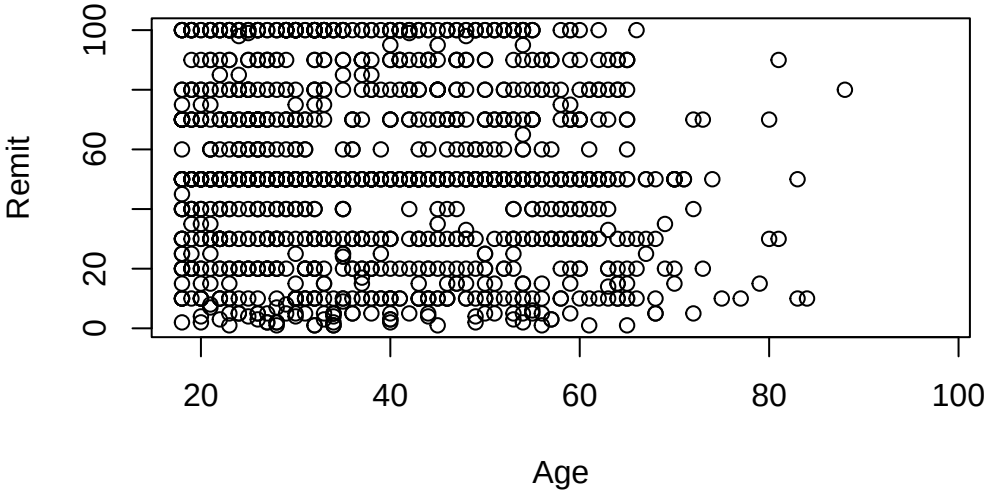

10.2 lattice

Теперь давайте воспользуемся пакетом *lattice* для дальнейшего анализа наших данных. Это один из пакетов с очень простым синтаксисом для группировки данных.

```
xyplot(Remit~Age, groups=Country, auto.key=list(space="right"))
```

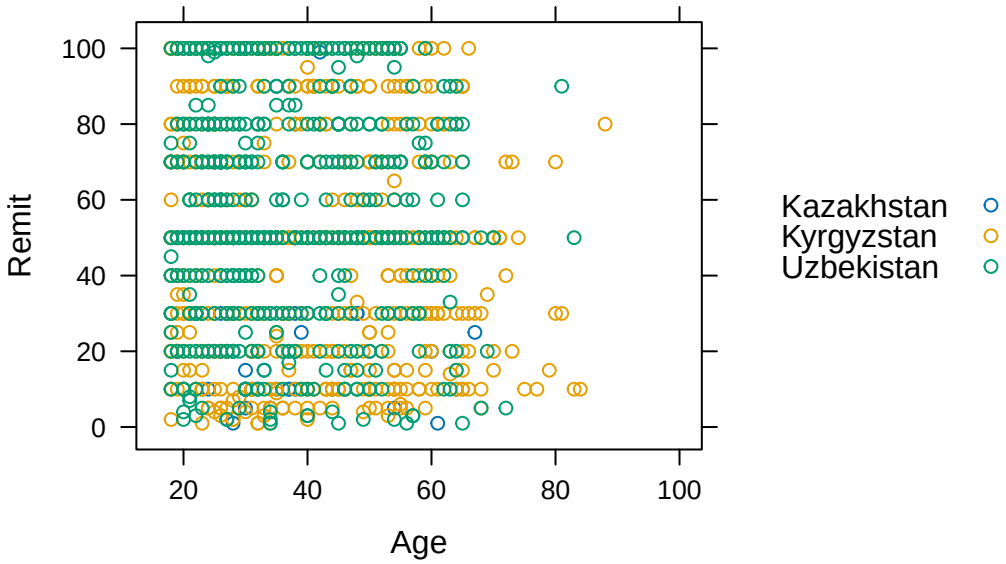


```
xyplot(Remit~Age | Country, groups=Language, auto.key=list(space="right"))
```

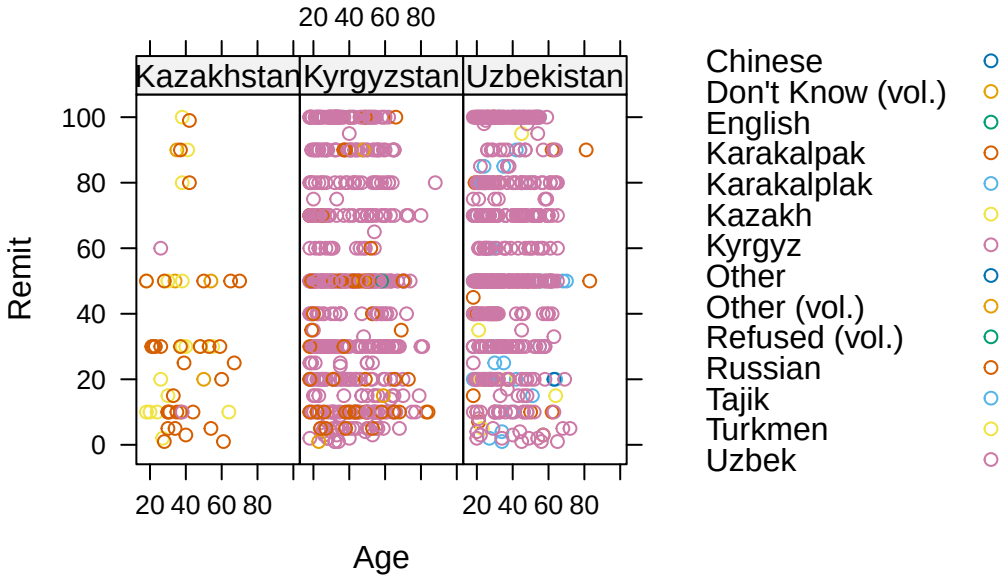


```
xyplot(Remit~Age | Country, groups=Marital, pch=10,
 ↪  auto.key=list(space="right"))
```

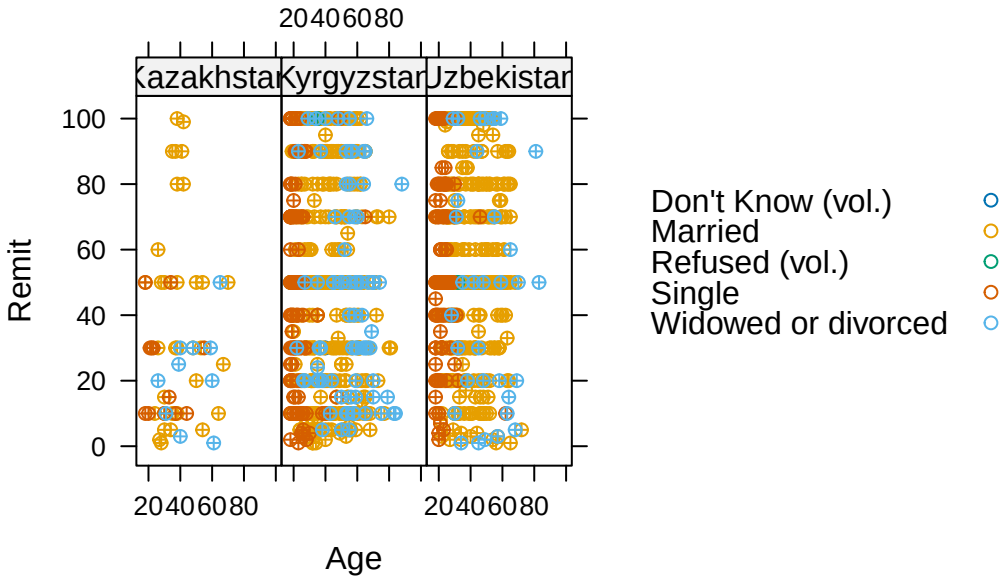

10.3 ggplot

Теперь давайте изучим использование *ggplot*, одного из самых, если не самого, популярных инструментов визуализации в R. Он популярен как минимум по двум причинам. Во-первых, поведение большинства графиков по умолчанию достаточно сложное и использует хорошие принципы визуализации. Во-вторых, он очень настраиваемый и гибкий благодаря тому, как элементы синтаксиса взаимодействуют друг с другом.

Сначала давайте рассмотрим использование «эстетики», элемента внешнего вида и стиля синтаксиса «Грамматики графики», а затем использование меток для уточнения и улучшения наших графиков.

```
ggplot(my_final_data, aes(y=Remit, x=Age))  + facet_grid(.~Country) +
↪  geom_point(aes(color=Sex))
```

```
Warning: Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

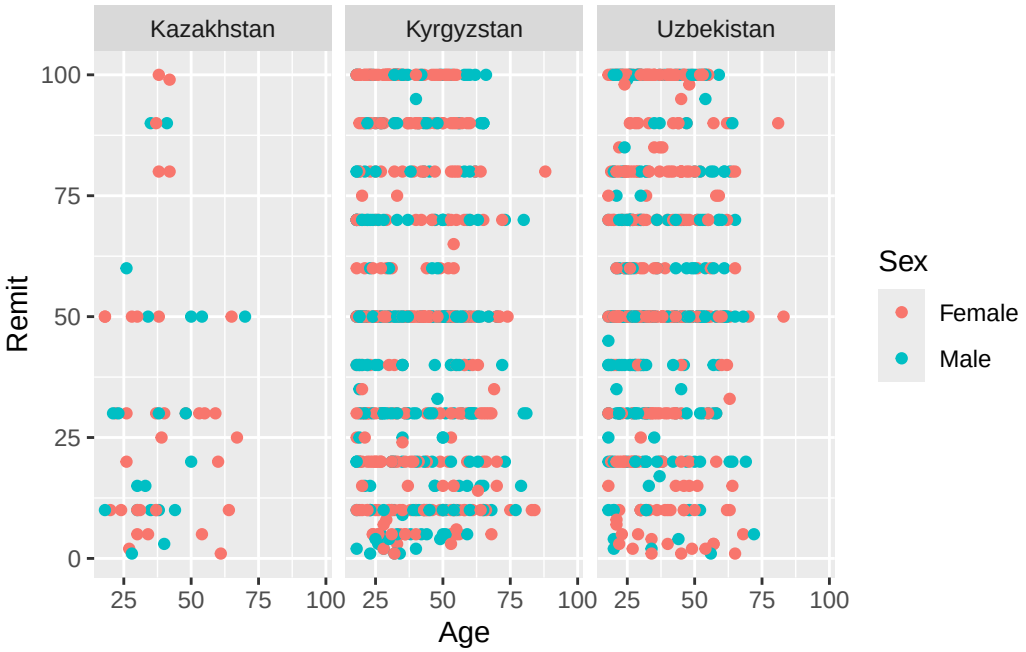


```
ggplot(my_final_data, aes(y=Remit, x=Age))  + facet_grid(Country~.) +
↪  geom_point(aes(color=Marital))
```

```
Warning: Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

```
ggplot(my_final_data, aes(y=Remit, x=Age))  + facet_grid(Country~.) +
 ↪  geom_point(aes(color=Marital))+
labs(x="age", y="% remittances", title="Remittance as percentage of income")
```

```
Warning: Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

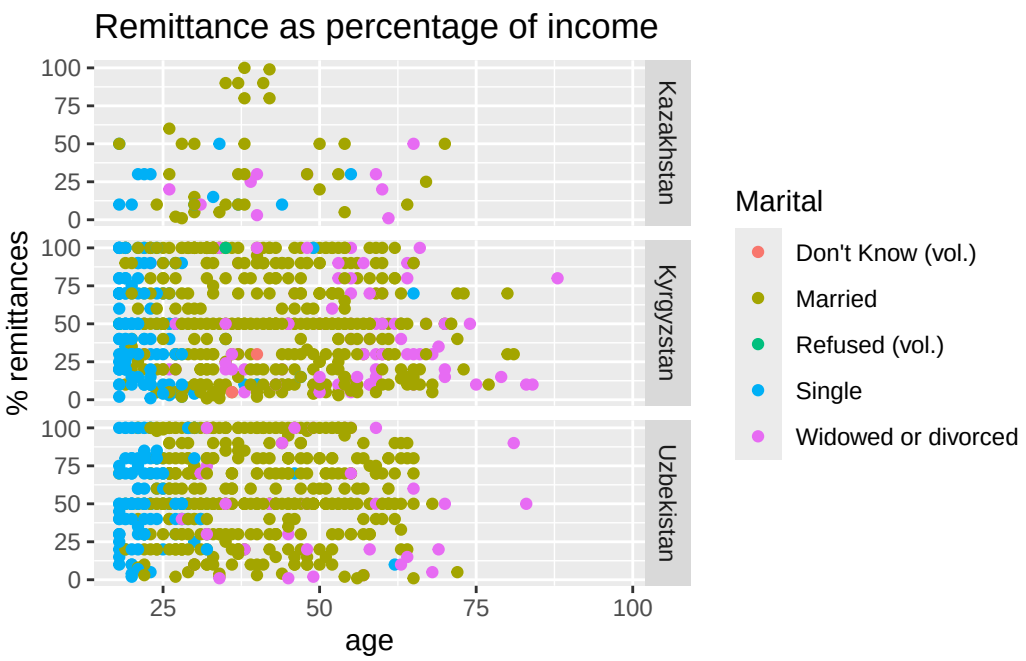


```
ggplot(my_final_data, aes(x=Remit, y=Age))  + facet_grid(.~Country) +
 ↪  geom_point(aes(color=Marital))+
  labs(x="age", y="% remittances", title="Remittance as percentage of
   ↪  income")
```

```
Warning: Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

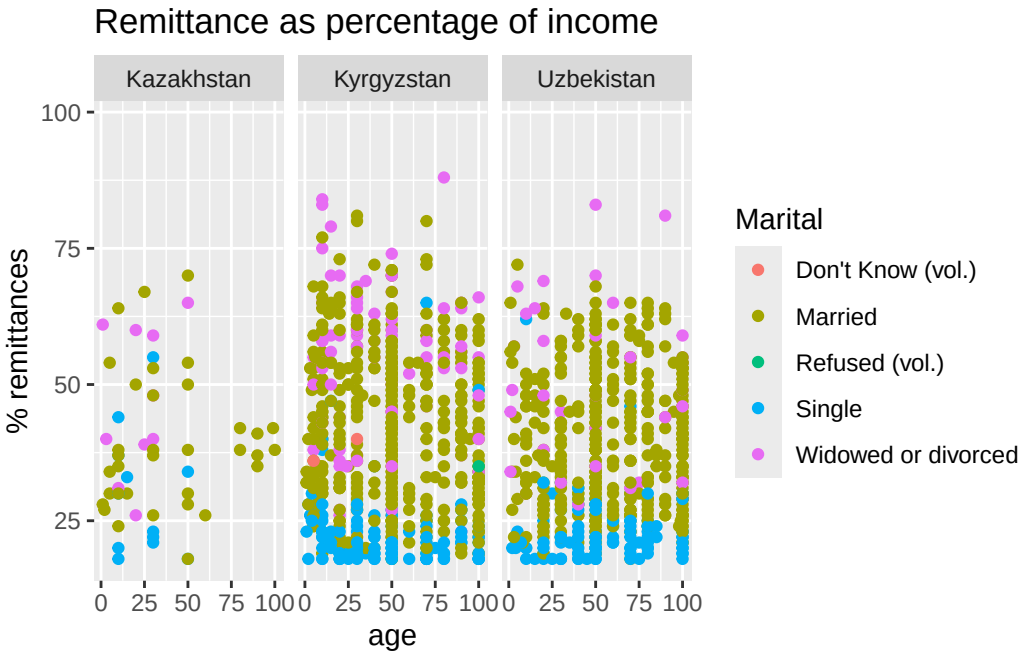


```
# point size

ggplot(my_final_data, aes(x=Remit, y=Age))  + facet_grid(.~Country) +
 ↪  geom_point(aes(color=Marital), size=3)+
  labs(x="age", y="% remittances", title="Remittance as percentage of
   ↪  income")
```

```
Warning: Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

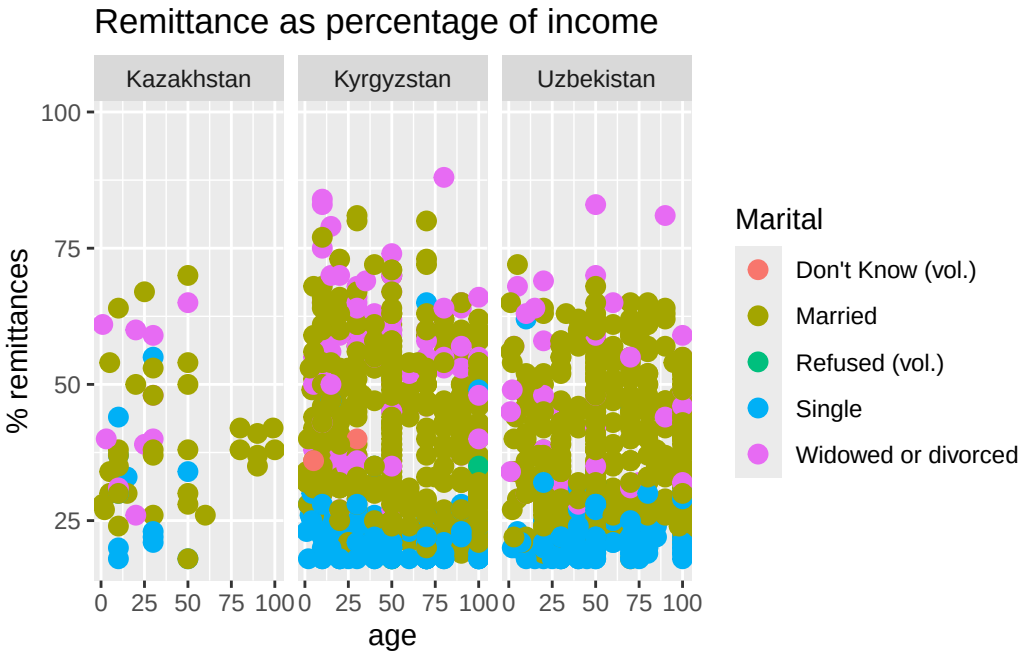

10.4 Столбчатая диаграмма

Обратите внимание на последнюю настройку, изменяющую размер точки, которая является частью параметров geom_point. Но, поскольку большая часть наших данных является категориальной, мы получим более наглядное представление о наших данных, работая с гистограммами, переходя от самых простых и скучных примеров к примерам, где мы используем возможности ggplot для изменения внешнего вида и отображения более сложной информации, а также для сравнения стран и временных периодов.

10.5 Цвета

Пакет *RColorBrewer* позволяет легко применять красиво масштабированные и затененные наборы цветов. Мы можем использовать R Color Picker, чтобы найти подходящие цвета, если хотим использовать *scale_fill_manual* для предоставления списка цветов (в данном случае, соответствующих флагам стран). Наконец, страница посвященная цветам в ggplots предоставляет множество полезной информации.

```
ggplot(my_final_data, aes(x=Sex)) + geom_bar(position="stack")
```

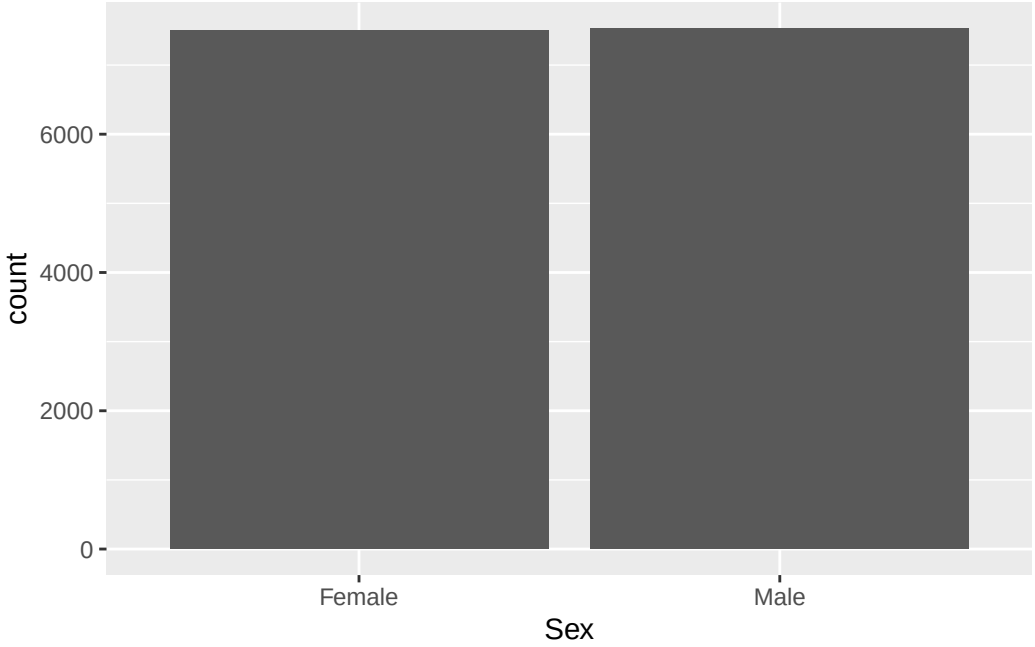


```
ggplot(my_final_data, aes(x=Sex, fill=Country)) + geom_bar(position="stack")
```

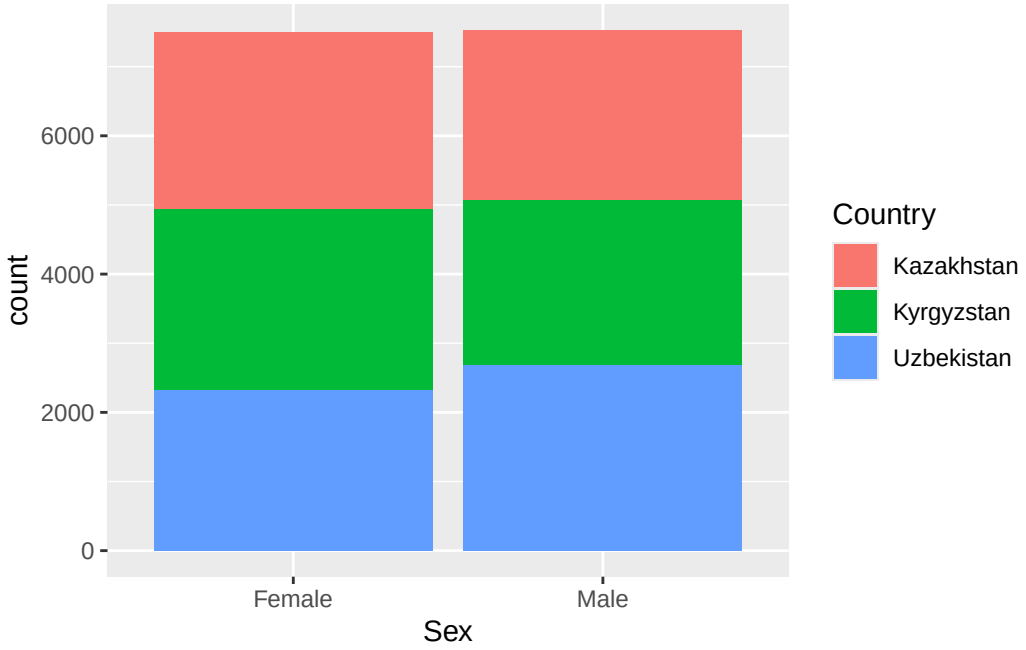


```
country_colors <- c("turquoise1","firebrick1","seagreen3")

ggplot(my_final_data, aes(x=Sex, fill=Country)) + geom_bar(position="stack")
 ↪  + scale_fill_manual(values = country_colors)
```

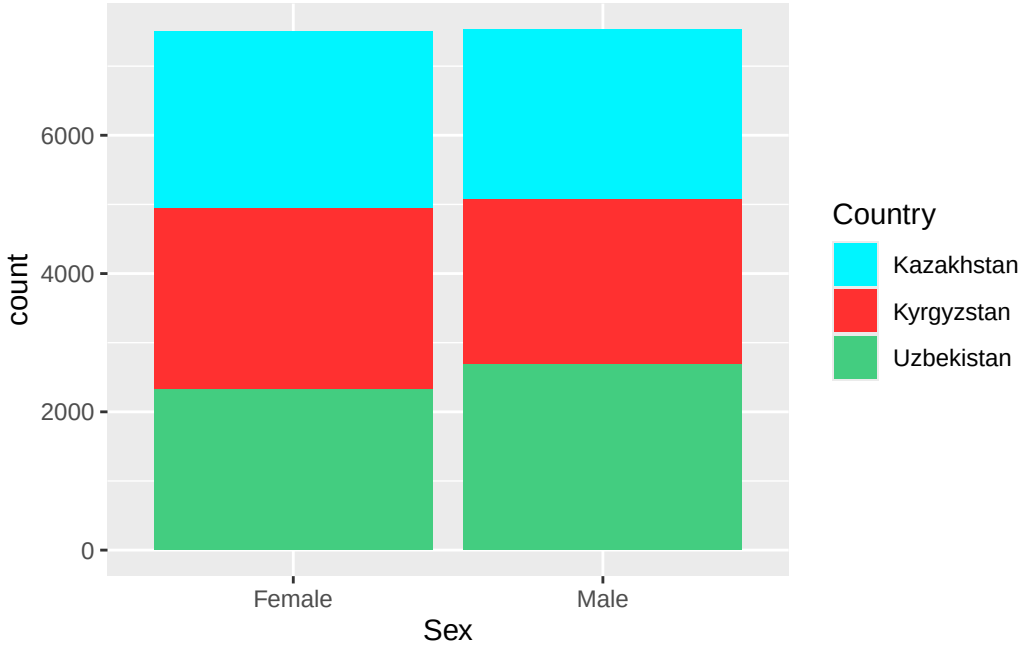


```
ggplot(my_final_data, aes(x=Sex, fill=Country)) + geom_bar(position="stack")
 ↪  + scale_fill_brewer(palette = "Accent")
```

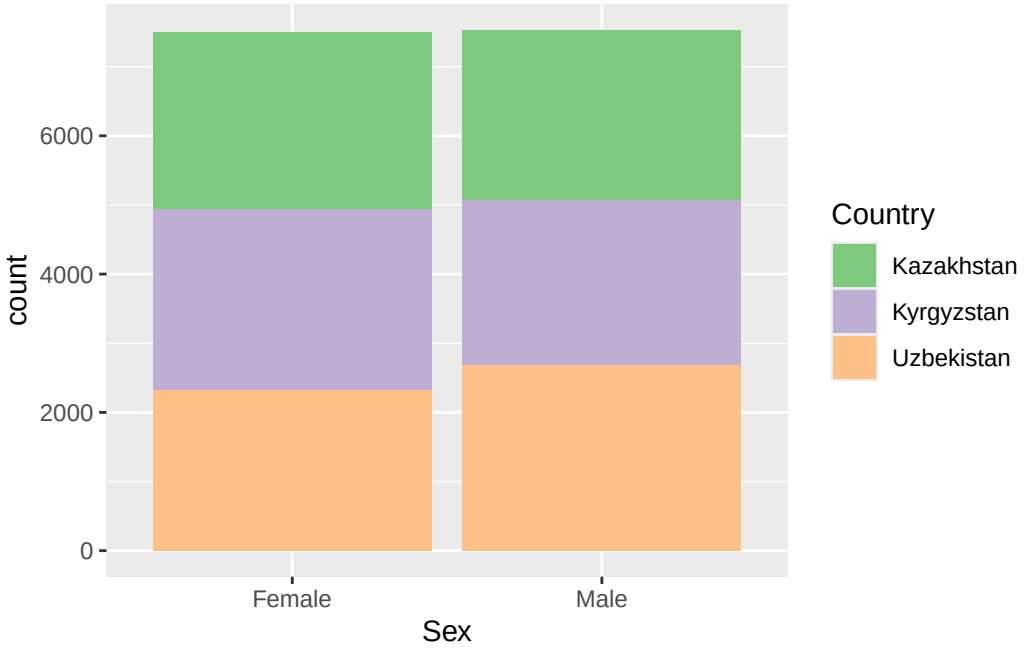

Пакет *paletteer* предлагает головокружительное множество вариантов выбора цвета, но также предоставляет инструменты, включая инструмент поиска цветовой палитры, которые делают этот выбор более удобным. Названия палитр иногда совпадают с цветами, которые они предоставляют. Как вы думаете, палитра *samarqand2* соответствует цветам плиток в Регистан?

```
ggplot(my_final_data, aes(x=Sex, fill=Country)) + geom_bar(position="stack")
 ↪  +scale_fill_paletteer_d("nationalparkcolors::Hawaii")
```

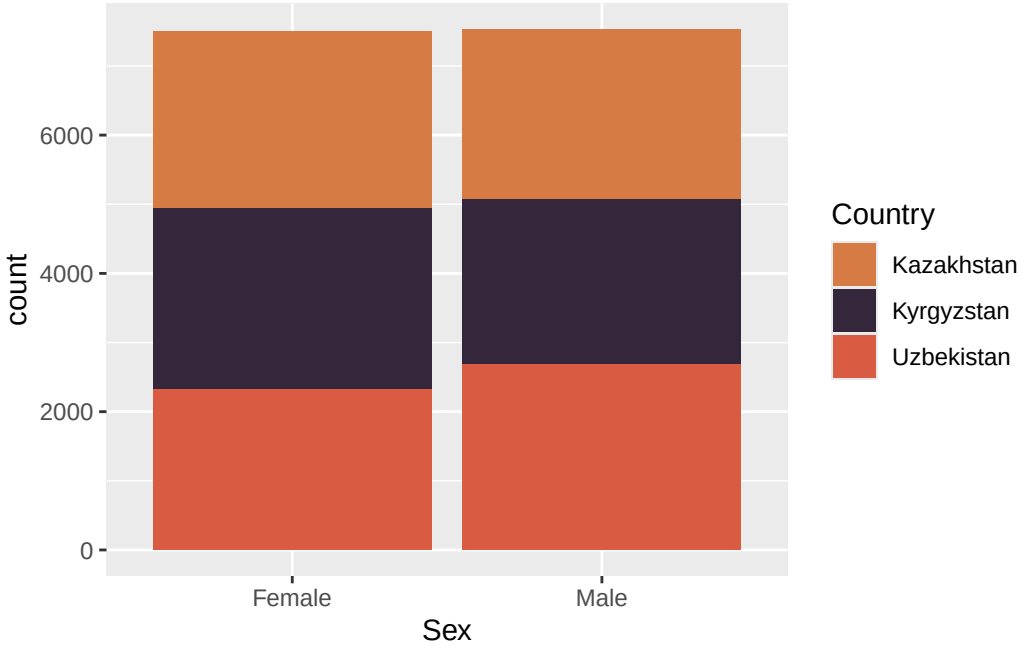


```
ggplot(my_final_data, aes(x=Sex, fill=Country)) + geom_bar(position="stack")
 ↪  +scale_fill_paletteer_d("IslamicArt::samarqand2")
```

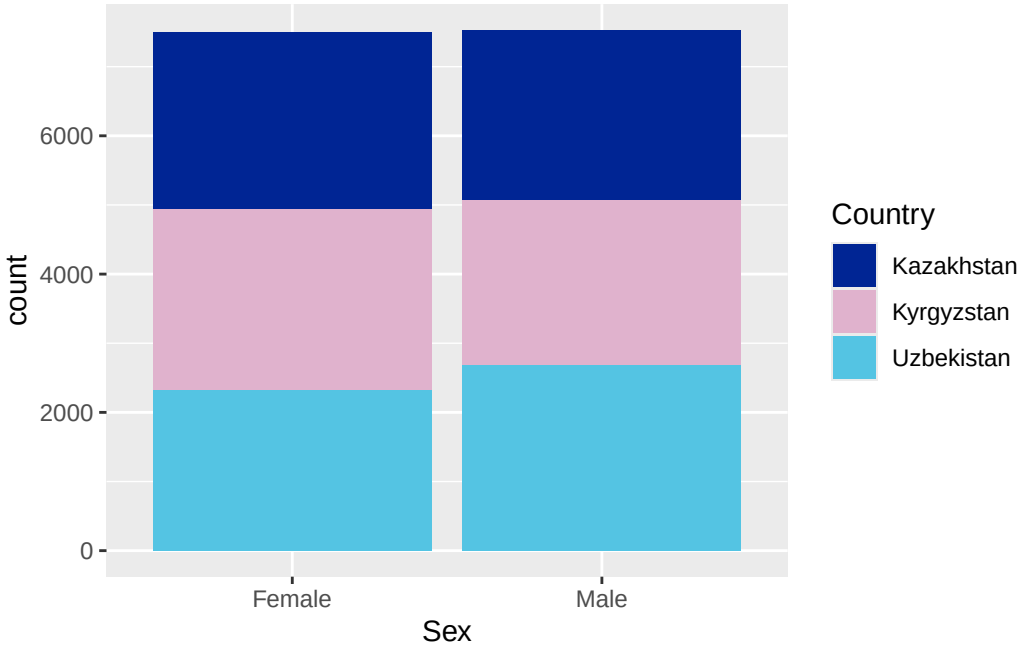


```
# try also
# IslamicArt::samarqand
# nbapalettes::lakers
# MoMAColors::OKeeffe
```

Давайте продолжим изучение данных, рассмотрев рейтинги благосклонности и настроив отображение по своему вкусу.

```
ggplot(my_final_data, aes(China_Favor, fill=Country))+
 ↪  geom_bar(position="stack") + scale_fill_manual(values = country_colors)
```

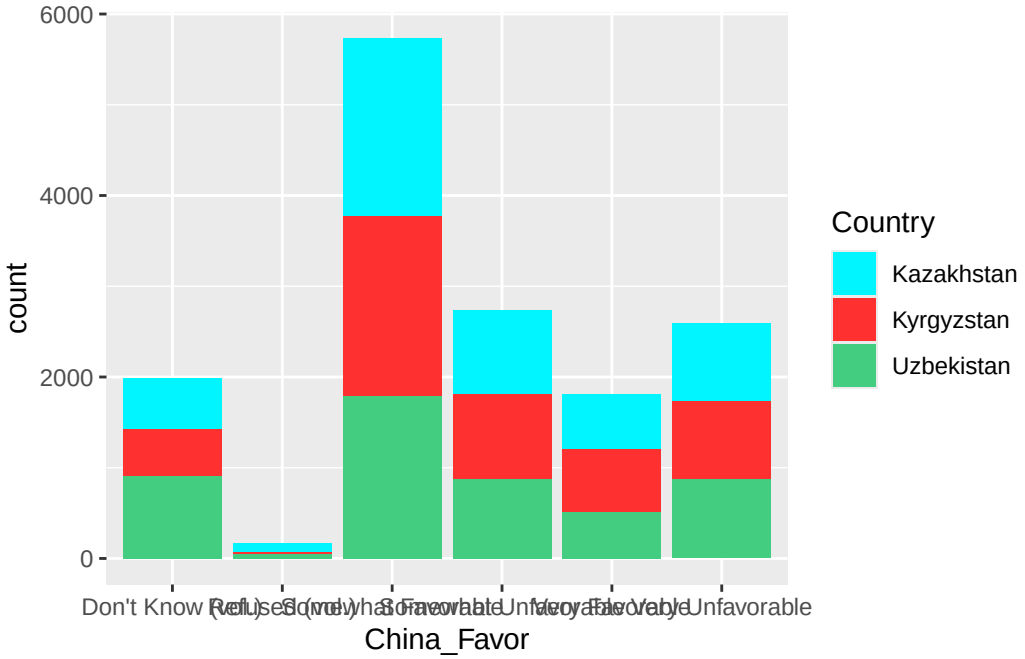

```
ggplot(my_final_data, aes(China_Favor, fill=Country))+
↪  geom_bar(position="dodge") + scale_fill_manual(values = country_colors)
```

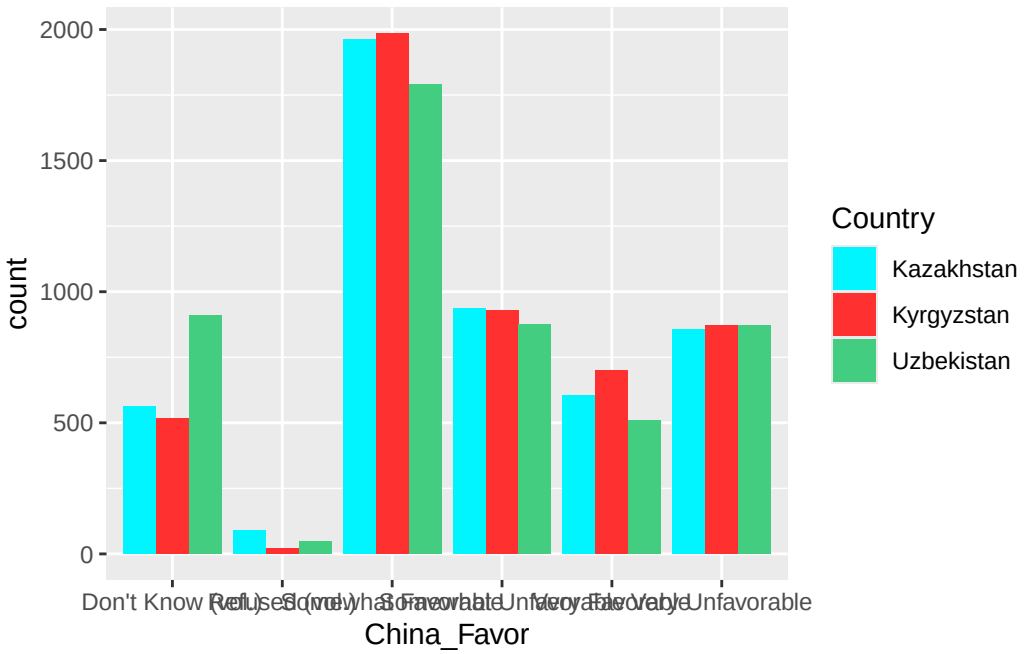


```
ggplot(my_final_data, aes(Russia_Favor, fill=Country))+
↪  geom_bar(position="dodge") + scale_fill_manual(values = country_colors)
```

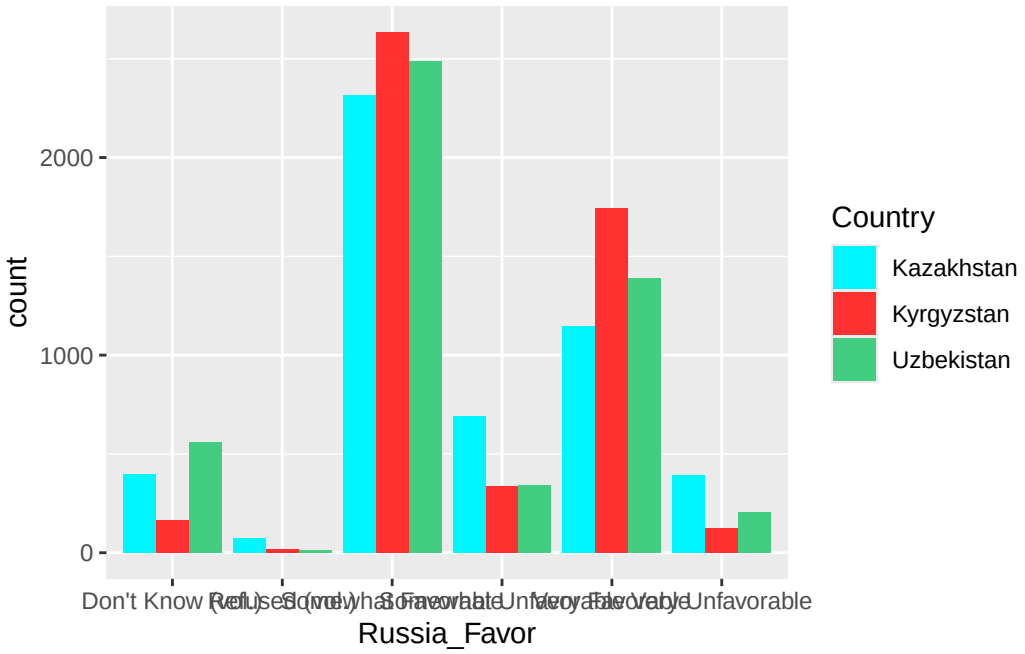


```
ggplot(my_final_data, aes(USA_Favor, fill=Country))+
↪  geom_bar(position="dodge") + scale_fill_manual(values = country_colors)
```

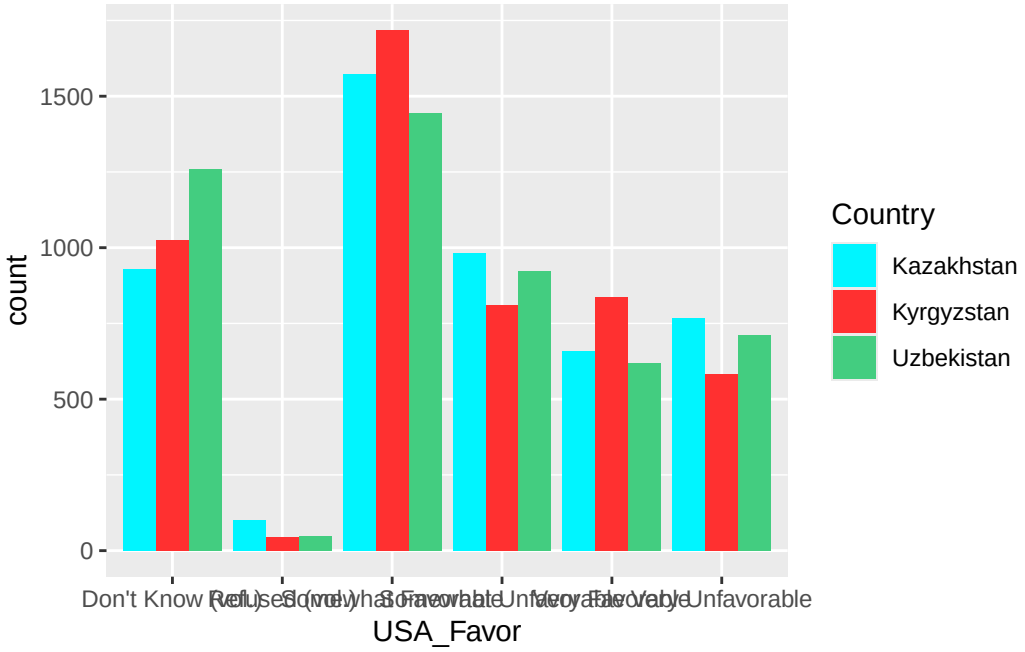

Мы можем экспортировать график и сохранить его как объект в R, используя оператор присваивания (<-). Это позволит нам легко повторно использовать изображения в различных контекстах, даже экспортировать и изменять их.

```
China <- ggplot(my_final_data, aes(China_Favor, fill=Country))+
 ↪  geom_bar(position="dodge") + scale_fill_manual(values = country_colors) +
 ↪  coord_flip()

Russia <- ggplot(my_final_data, aes(Russia_Favor, fill=Country))+
 ↪  geom_bar(position="dodge") + scale_fill_manual(values = country_colors) +
 ↪  coord_flip()

USA <- ggplot(my_final_data, aes(USA_Favor, fill=Country))+
 ↪  geom_bar(position="dodge") + scale_fill_manual(values = country_colors) +
 ↪  coord_flip()
```

Теперь мы воспользуемся пакетом *gridExtra* и его командой *grid.arrange*, чтобы объединить три графика благоприятности в один.

```
grid.arrange(China,Russia,USA, ncol=1, nrow=3)
```

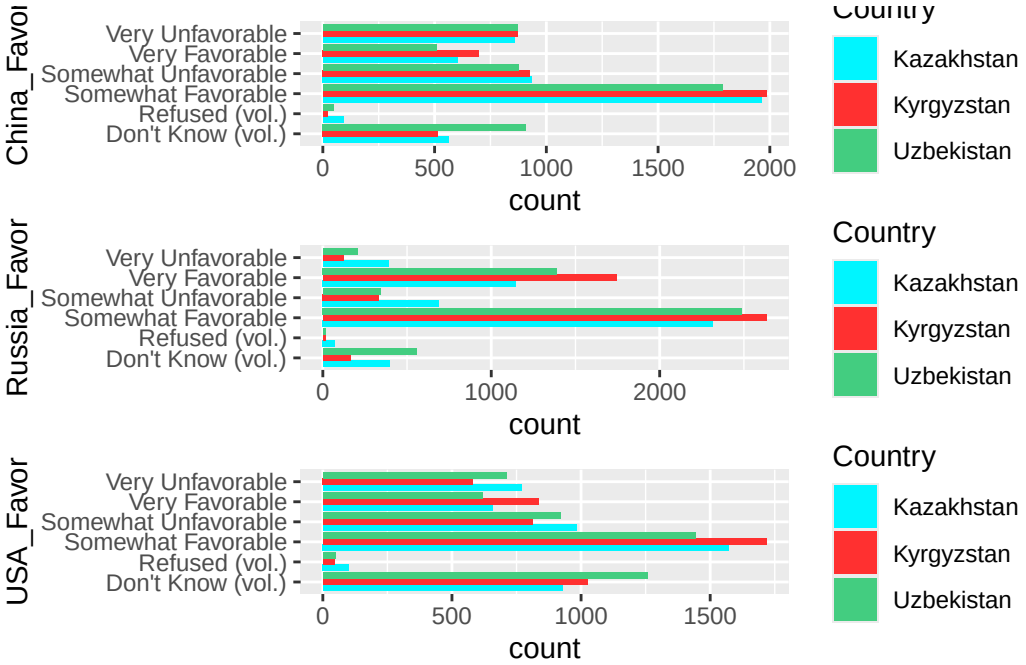

Мы можем экспортировать графики в статические файлы, сохраняемые на нашем компьютере. Процесс запускается командой, например, *pdf* для отправки результата в PDF-файл или *jpeg* для отправки в файл .jpg. Затем выполняется команда для работы с графикой (фактически, PDF-файл может содержать несколько графиков на дополнительных страницах). Эти графики не отображаются на экране, поскольку они отправляются в файл. Затем выполняется команда *dev.off* для прекращения перенаправления вывода в файл. После этого графики снова появятся на экране.

```
pdf(file="output.pdf")
ggplot(my_final_data, aes(USA_Favor, fill=Country))+
 ↪  geom_bar(position="dodge") + scale_fill_manual(values = country_colors) +
 ↪  coord_flip()
dev.off()
```

```
pdf
  2
```

```
jpeg(file="output.jpg", width = 800, height = 600, quality=100)
ggplot(my_final_data, aes(x=Sex, fill=Country)) + geom_bar(position="stack")
 ↪  +scale_fill_paletteer_d("IslamicArt::samarqand2")
dev.off()
```

```
pdf
  2
```

10.6 Гистограмма

Чтобы показать другие возможности, рассмотрим гистограммы и способы их настройки. Здесь мы также продемонстрируем использование опции *theme*.

```
ggplot(my_final_data, aes(Age))+geom_histogram(aes(fill =
↪  after_stat(count)))+facet_grid(Country~.)
```

```
`stat_bin()` using `bins = 30`. Pick better value `binwidth`.
```

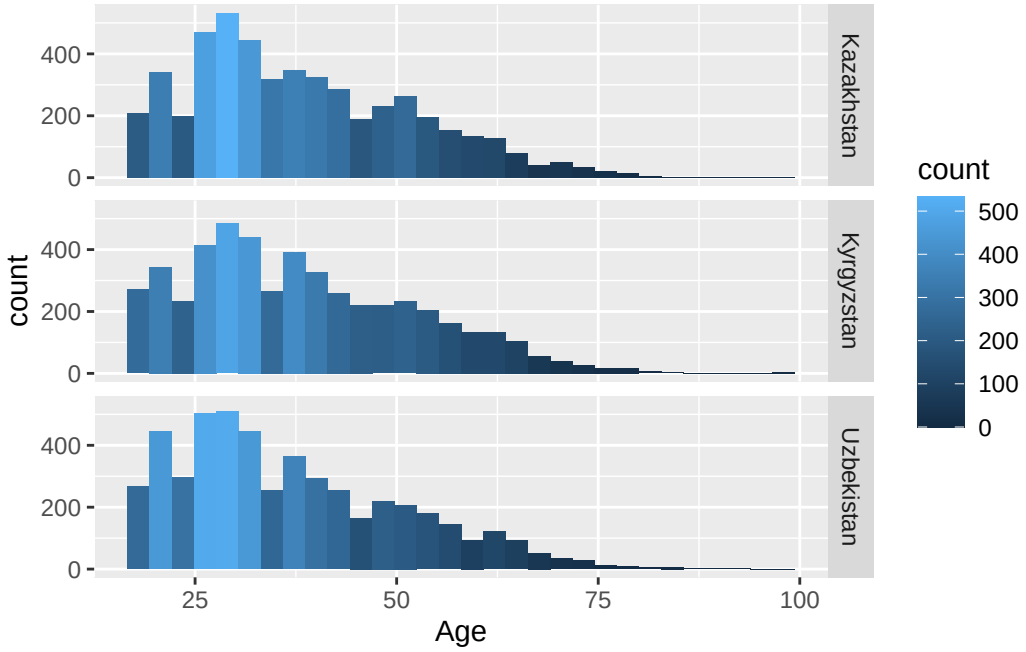


```
ggplot(my_final_data, aes(Age)) + facet_grid(Country~.) +
↪  geom_bar(position="dodge", fill="olivedrab")+theme(panel.background =
↪  element_rect(fill='lightsteelblue1', colour='darkblue'))
```

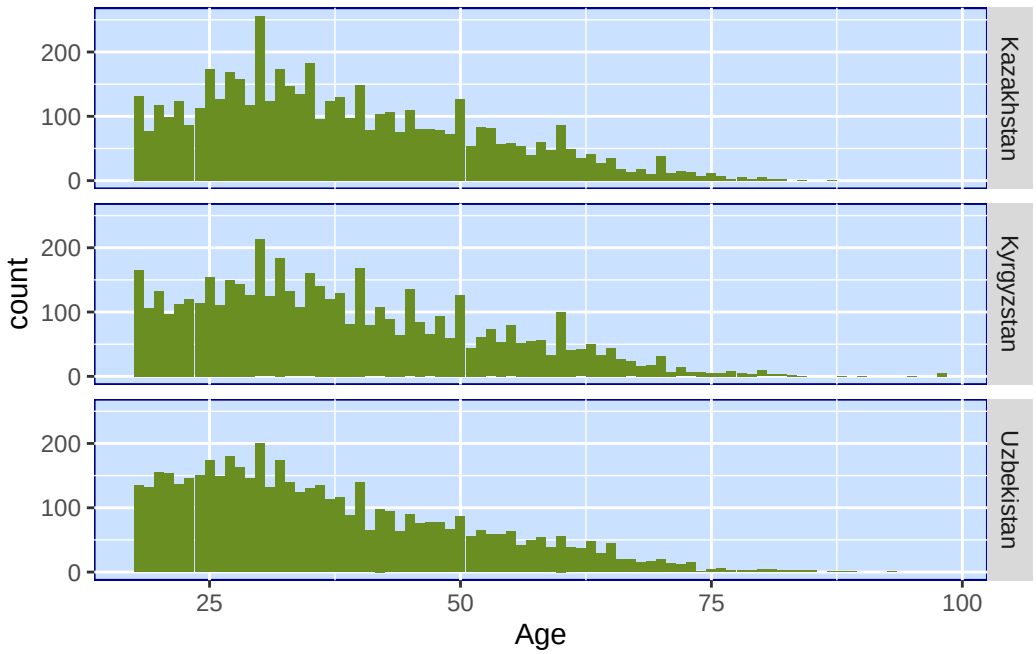

```
ggplot(my_final_data, aes(Age)) + facet_grid(Country~.) +
↪  geom_bar(position="dodge")+theme(panel.background =
↪  element_rect(fill='white', colour='black'))
```

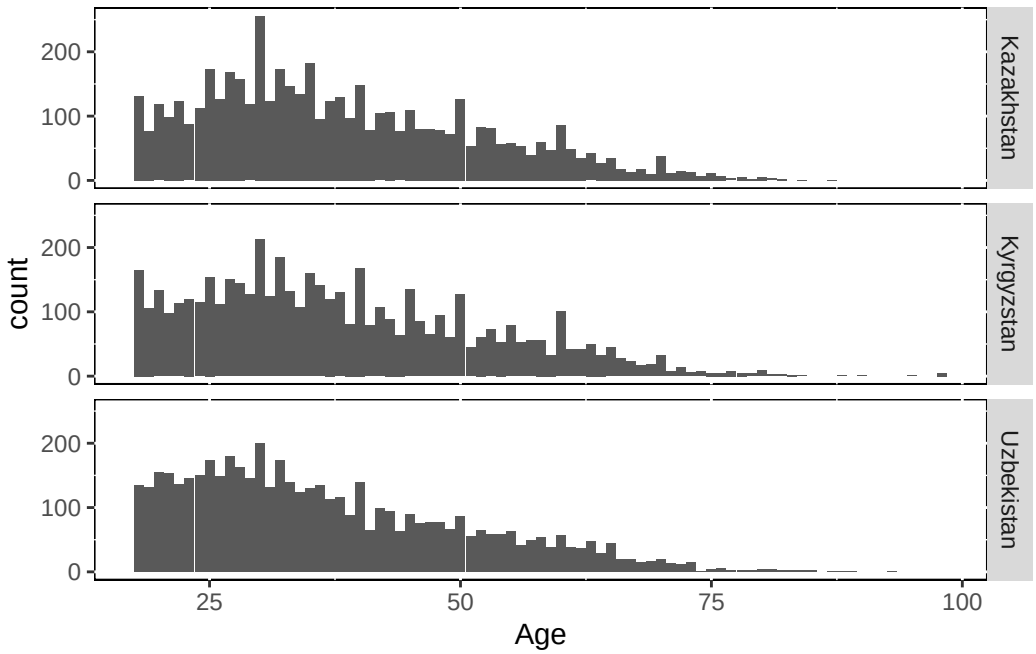


```
ggplot(my_final_data, aes(Age)) + facet_grid(Country~.) +
↪  geom_bar(position="dodge")+ scale_fill_brewer(palette="Reds")
```

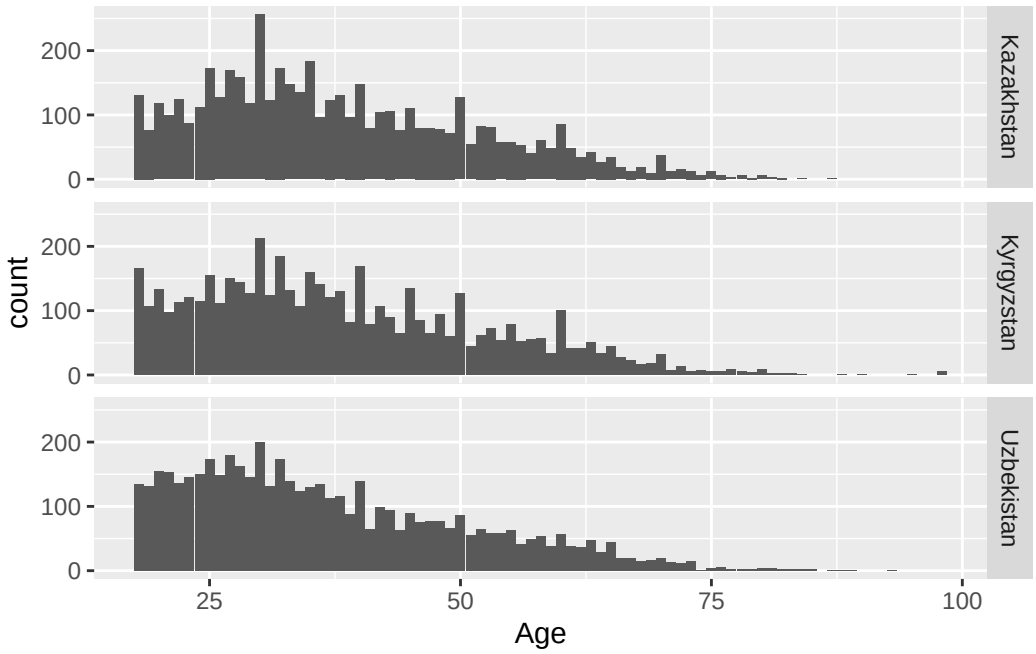


```
ggplot(my_final_data, aes(Employment_recode, fill=as.factor(Marital_recode)))
↪  +facet_grid(Country~.) + geom_bar(position="dodge") +
↪  theme(panel.background = element_rect(fill='beige', colour='darkblue'))
```

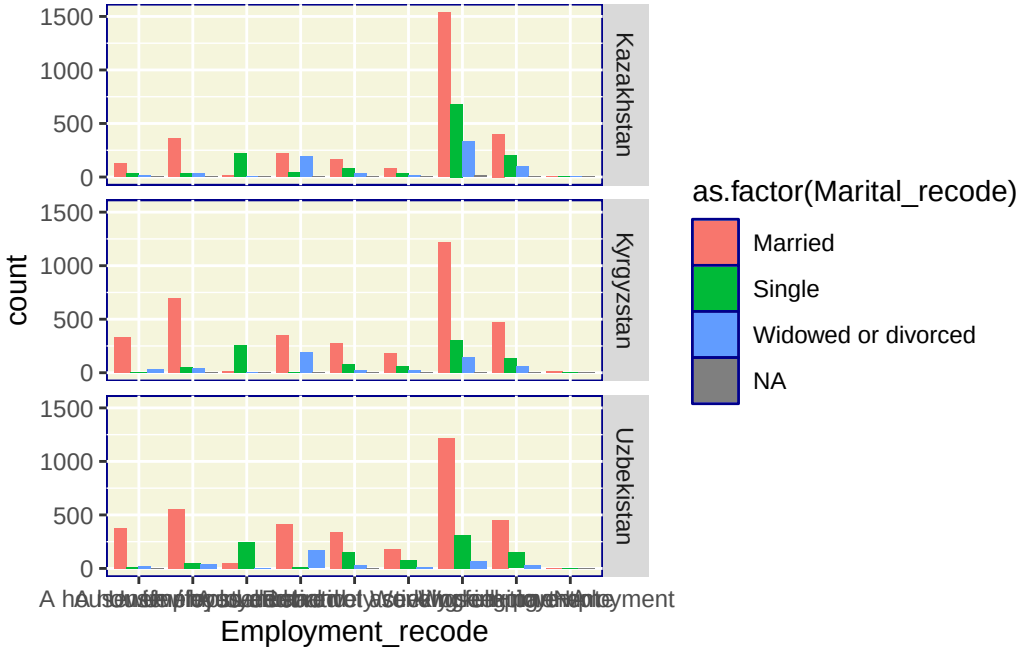


```
ggplot(my_final_data, aes(Employment_recode, fill=as.factor(Marital_recode)))
↪  +facet_grid(Country~.) + geom_bar(position="dodge") +
↪  theme(panel.background = element_rect(fill='beige', colour='darkblue')) +
 labs(x="Work status", y="Count", title="Employment by Marital Status") +
  ↪  coord_flip()
```

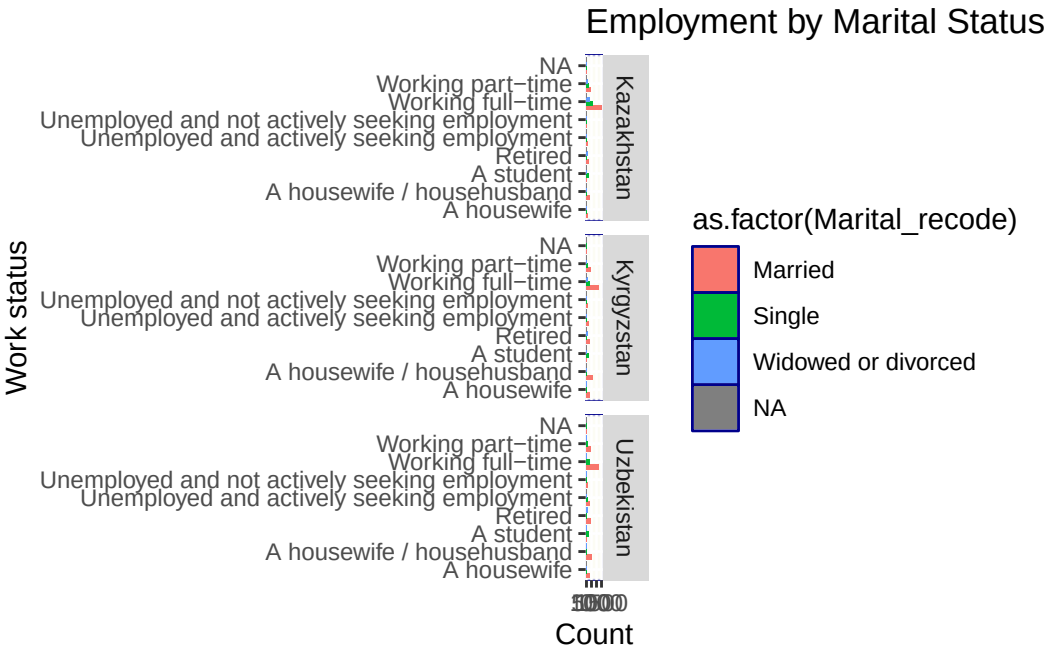


```
ggplot(my_final_data, aes(Employment_recode2,
↪  fill=as.factor(Marital_recode))) +facet_grid(Country~.) +
↪  geom_bar(position="dodge") + theme(panel.background =
↪  element_rect(fill='beige', colour='darkblue')) +
```

```
  labs(x="Work status", y="Count", title="Employment by Marital Status") +
 ↪  coord_flip()
```

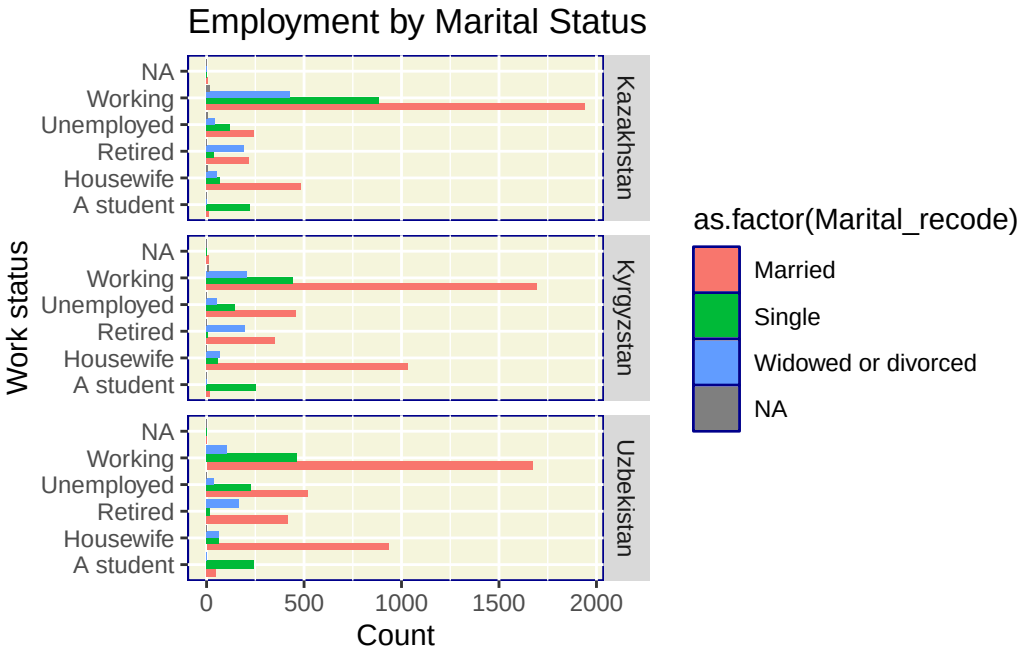


```
ggplot(my_final_data, aes(Employment_recode2, fill=Country))
 ↪  +facet_grid(Marital_recode~.) + geom_bar(position="dodge") +
 ↪  scale_fill_manual(values=country_colors)+theme(panel.background =
 ↪  element_rect(fill='beige', colour='darkblue')) +
  labs(x="Work status", y="Count", title="Employment by Marital Status")
```

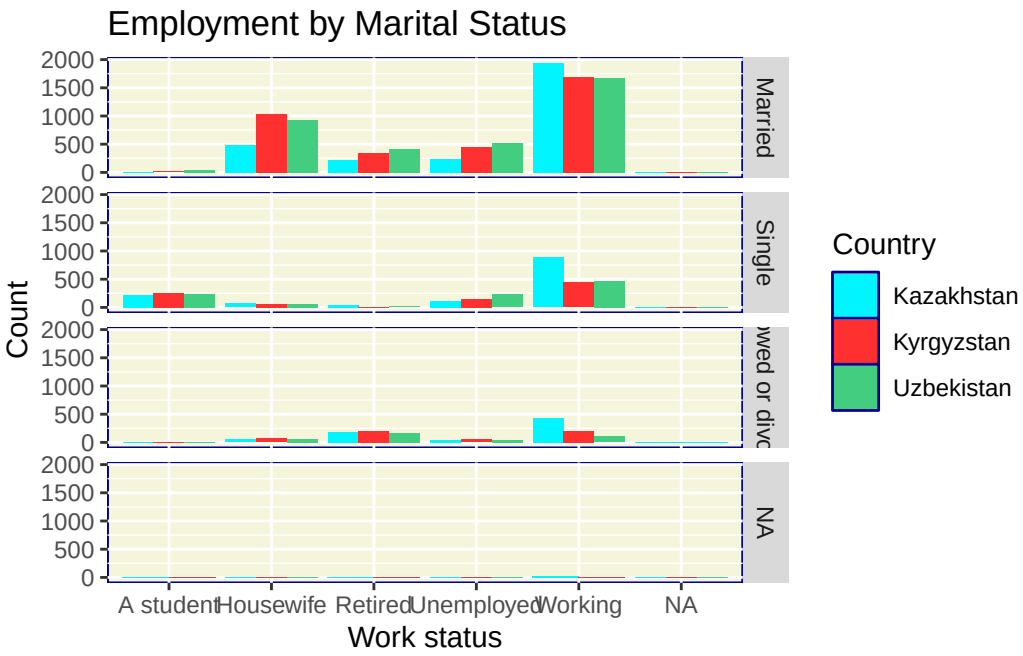

Внимательно изучите вопрос о направлении движения:

```
# Direction by factors
```

```
ggplot(my_final_data, aes(Direction, fill=Country)) +
↪  geom_bar(position="dodge") +
↪  scale_fill_manual(values=country_colors)+theme(panel.background =
↪  element_rect(fill='beige', colour='darkblue')) +
  labs(x="Response", y="Count", title="Going in Right or Wrong Direction?")
```

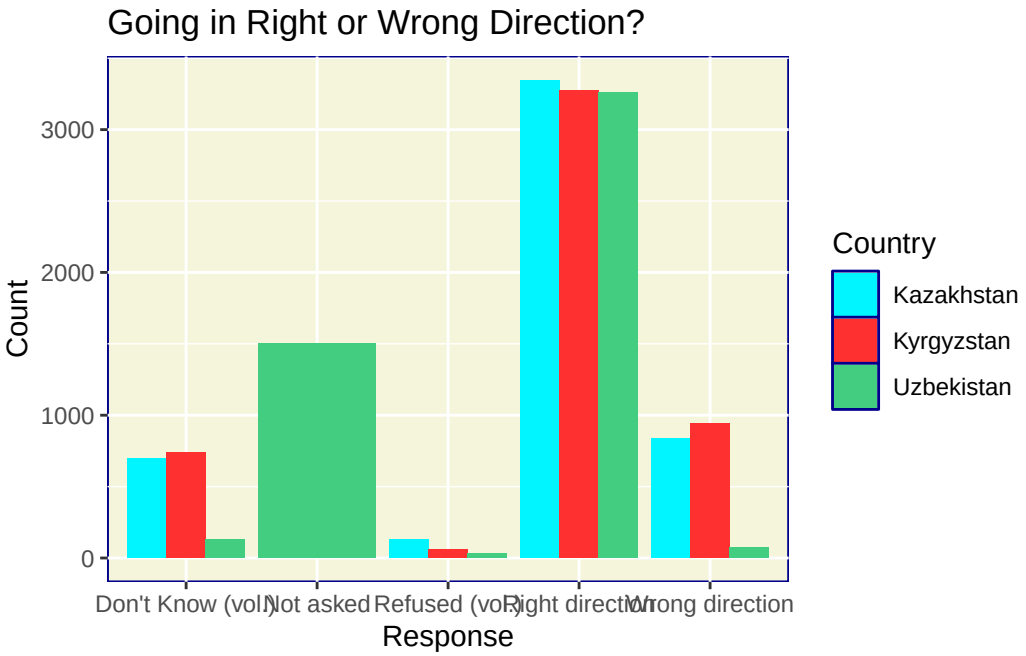


```
ggplot(my_final_data, aes(Direction, fill=Country)) + facet_grid(Year~.) +
↪  geom_bar(position="dodge") +
↪  scale_fill_manual(values=country_colors)+theme(panel.background =
↪  element_rect(fill='beige', colour='darkblue')) +
  labs(x="Response", y="Count", title="Going in Right or Wrong Direction?")
```

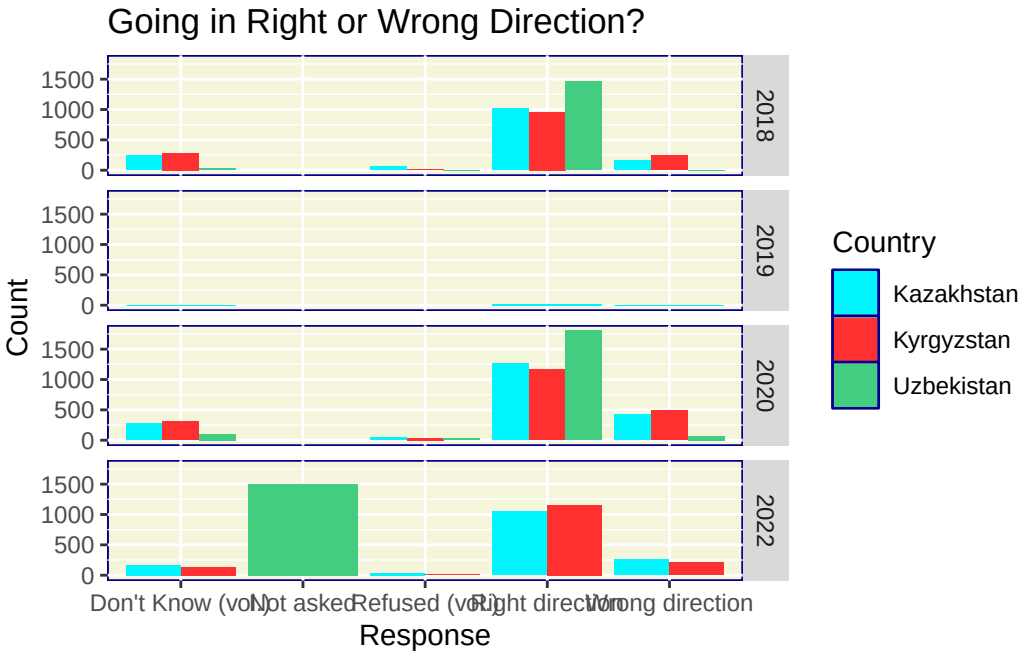


```
ggplot(my_final_data, aes(Direction_recode, fill=Country)) +
↪  facet_grid(Family_Fin_Sit_recode~.) + geom_bar(position="dodge") +
↪  scale_fill_manual(values=country_colors) + theme(panel.background =
↪  element_rect(fill='beige', colour='darkblue')) +
 labs(x="Response", y="Count", title="Going in Right or Wrong Direction vs.
  ↪  Family situation?")
```

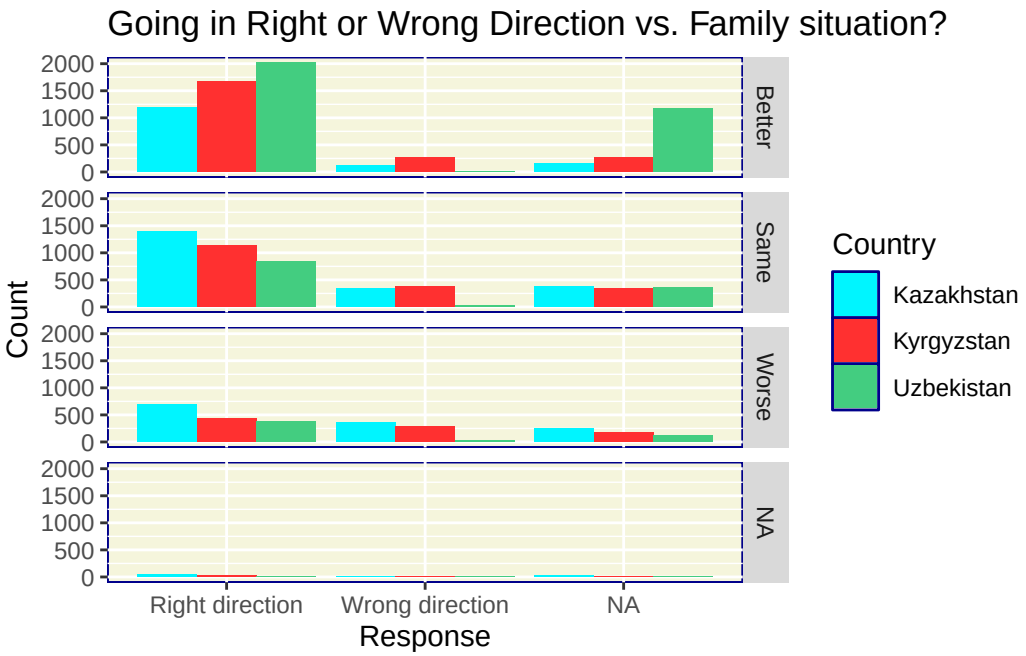

10.7 Используя силу

Мы можем использовать возможности грамматики графики и присваивать компоненты синтаксиса различным объектам, а затем объединять их в строки. Это может помочь нам упростить код и внести изменения и правки (например, изменив тему всех графиков одновременно).

```
mydata <- ggplot(my_final_data, aes(Direction_recode, fill=Country)) +
 ↪  facet_grid(Family_Fin_Sit_recode~.) +
  labs(x="Response", y="Count", title="Going in Right or Wrong Direction vs.
   ↪  Family situation?") + scale_fill_manual(values=country_colors)

mytheme <- theme(panel.background = element_rect(fill='beige',
 ↪  colour='darkblue'))

mychart <- geom_bar(position="dodge")

mydata + mytheme + mychart
```

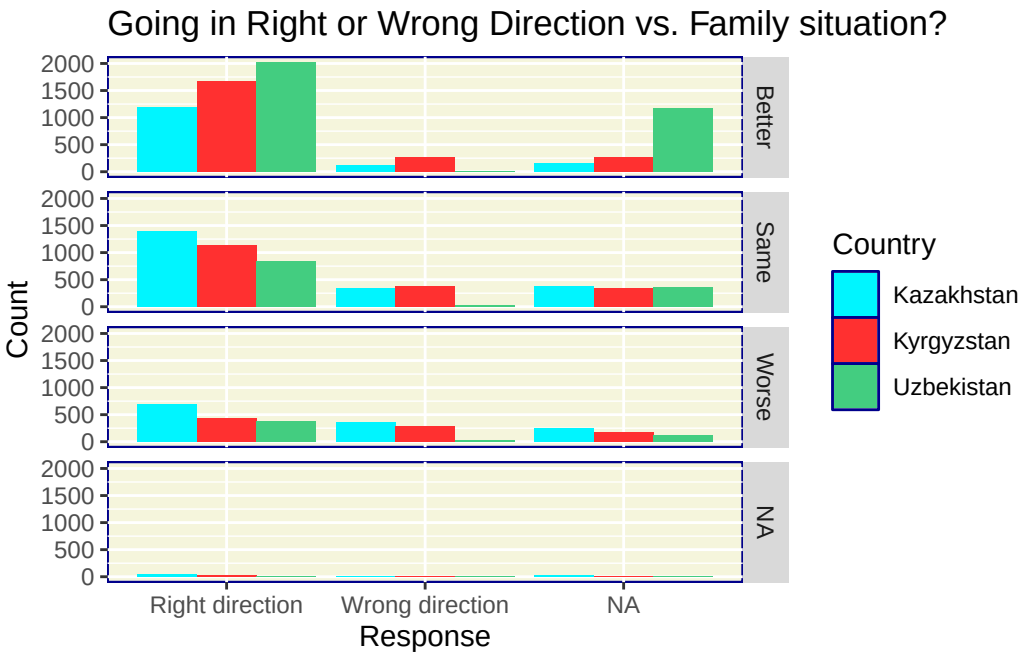

10.8 Другие сюжеты

Множество других графиков доступно через ggplot2. Ниже показана диаграмма размаха. Другие можно найти на справочной странице ggplot2 и в расширениях для ggplot2. Обратите внимание, что пакет *ggextra* может добавлять диаграммы размаха по краям диаграмм рассеяния. Обратите внимание, что темы существуют в таких пакетах, как *ggtheme* и *cowplot*.

```
ggplot(my_final_data, aes(x=Remit, y=Country)) + geom_boxplot()
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_boxplot()`).
```

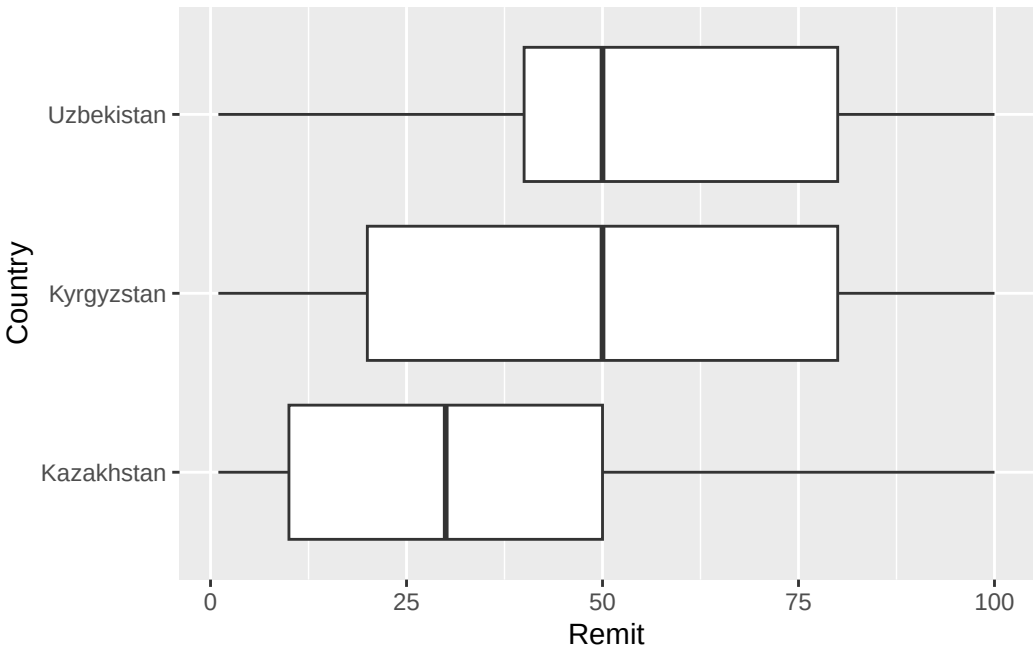


```
ggplot(my_final_data, aes(x=Remit, y=Country)) + geom_boxplot() +
↪  coord_flip()
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_boxplot()`).
```

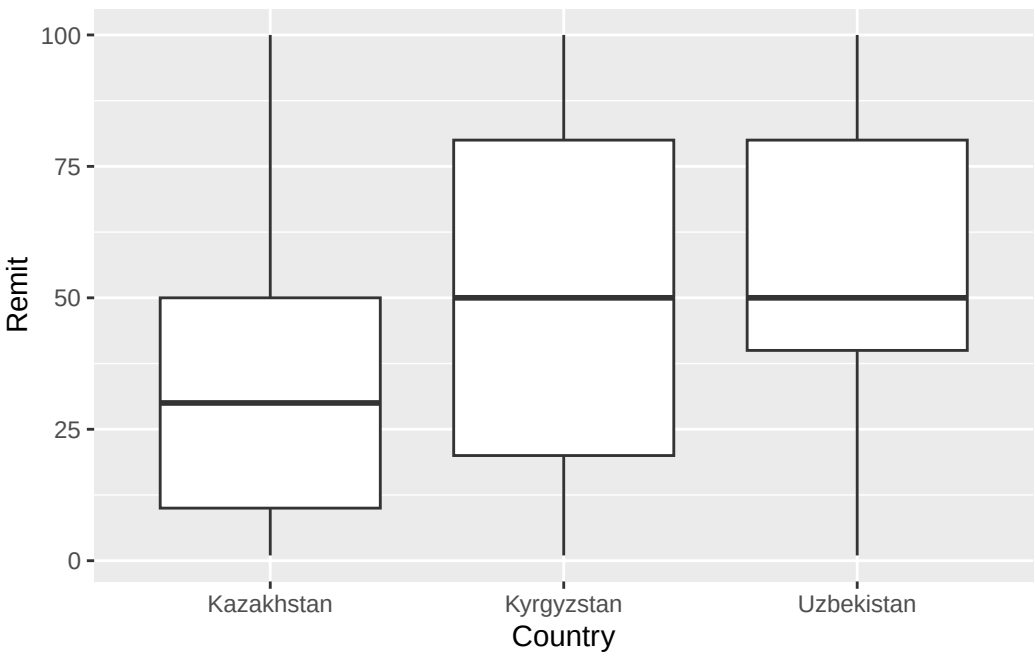

```
ggplot(my_final_data, aes(x=Remit, y=Country, fill=Country)) + geom_boxplot()
↪  + coord_flip() +
  theme_minimal_grid() + scale_fill_manual(values=country_colors)
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_boxplot()`).
```

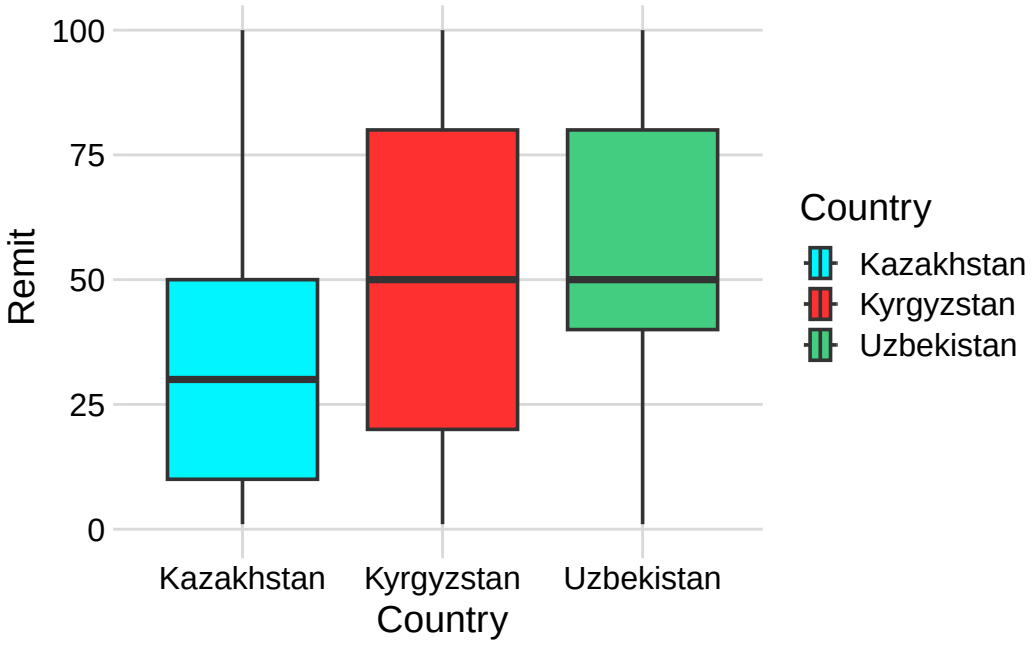

10.9 Темы

Дополнительные пакеты, такие как ggthemes (показан ниже), ggsci, ggthemr и другие, помогают нам быстро изменять внешний вид наших графиков в соответствии с нашими целями.

```
lastplot <- ggplot(my_final_data, aes(x=Remit,y=Age))  +
↪  geom_point(aes(color=Country)) + stat_smooth() +
  labs(x="Remittance %", y="Age", title="Age vs Remittance")
```

```
lastplot + theme_bw()
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
```

```
Warning: Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

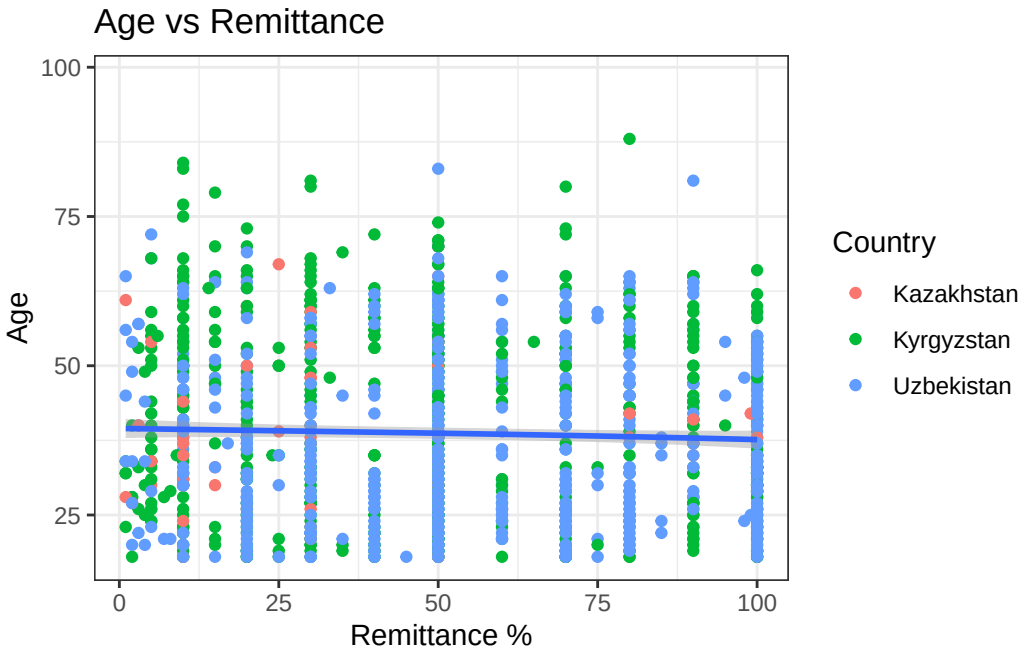


```
lastplot + theme_cowplot()
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

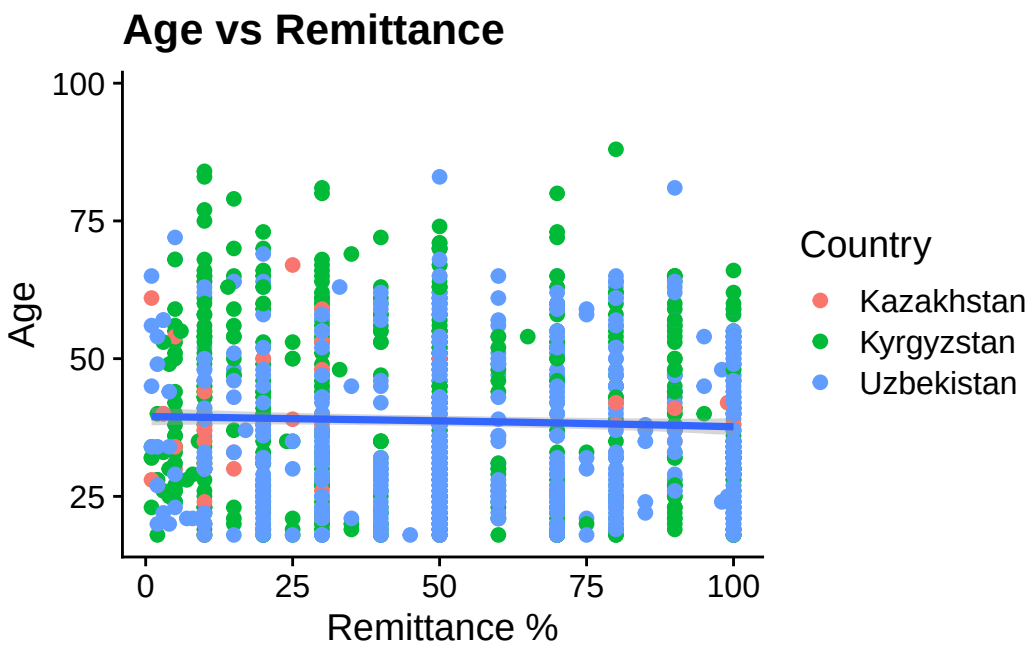


```
lastplot + theme_dark()
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'

Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

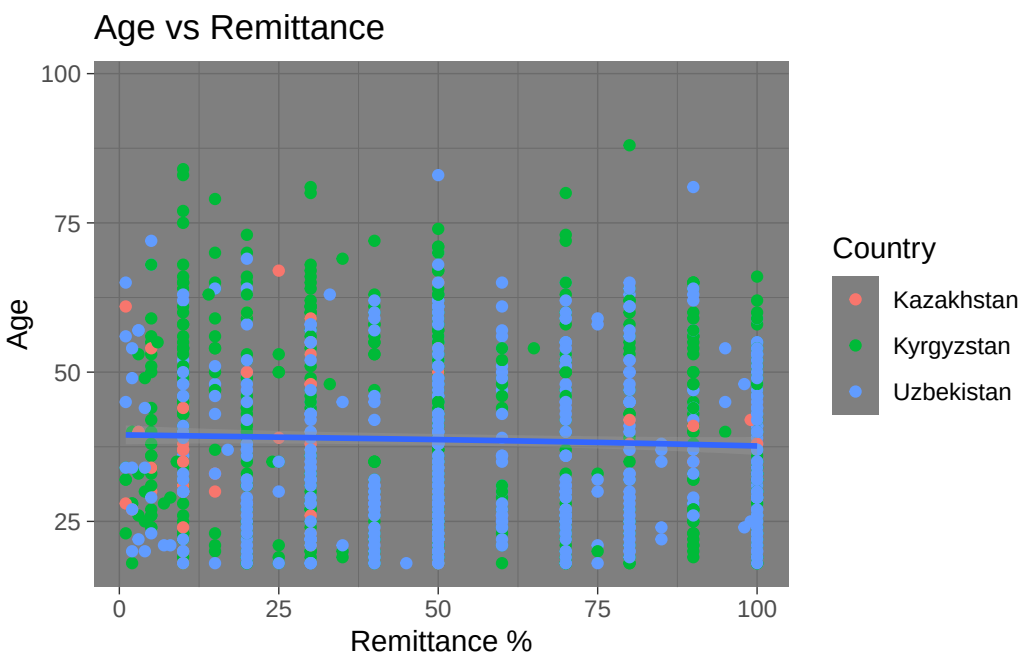


```
lastplot + theme_economist()

`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'

Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

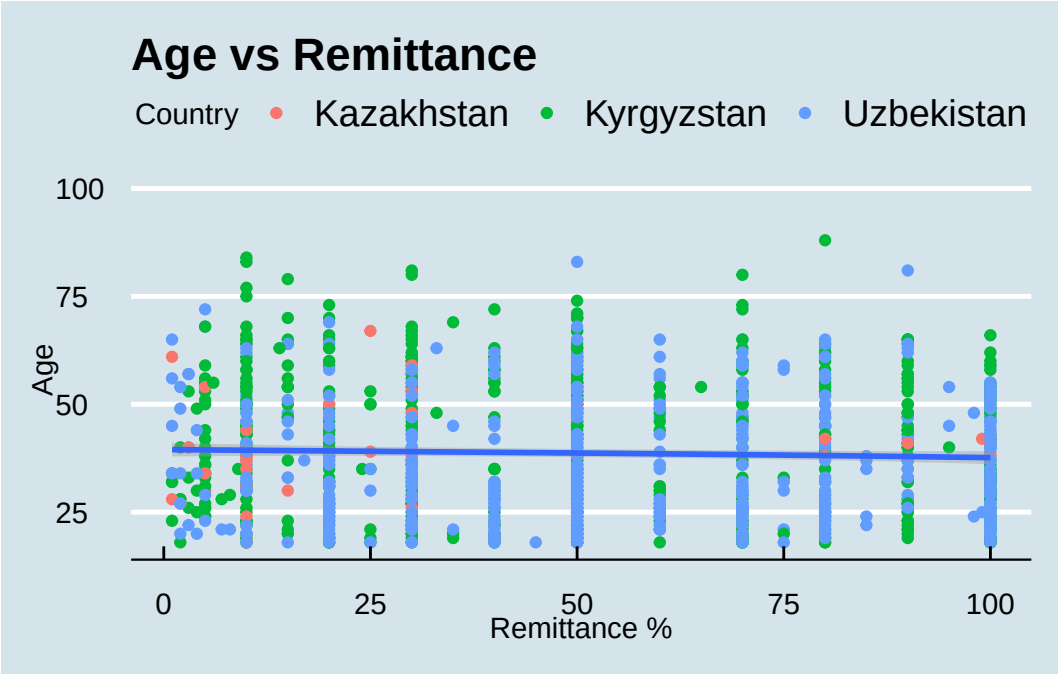


```
lastplot + theme_fivethirtyeight()
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

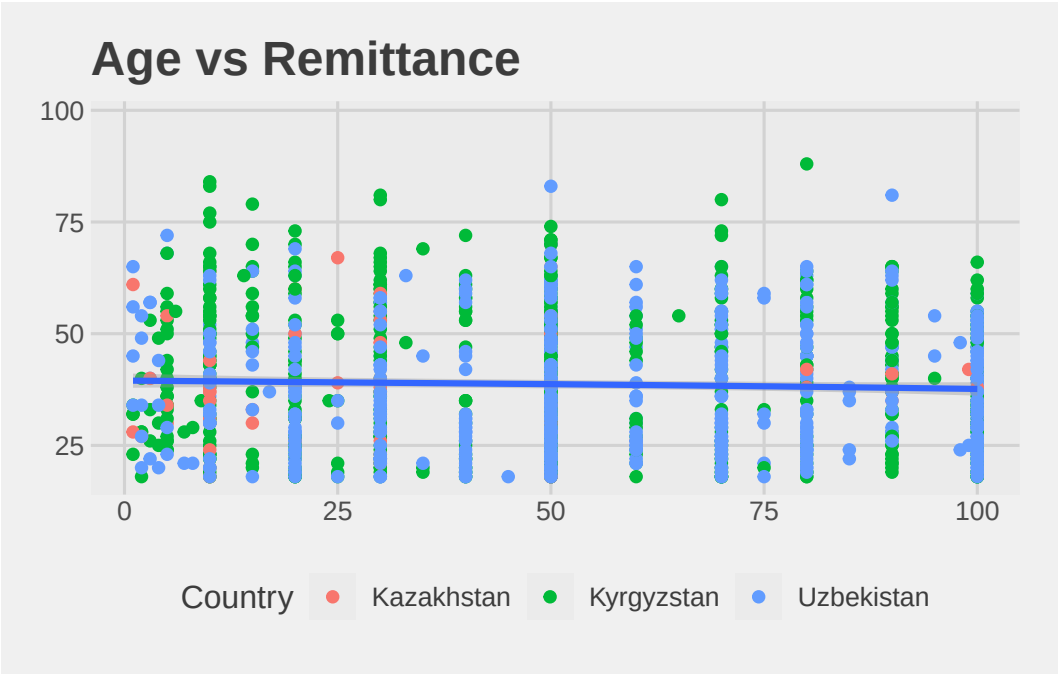

```
lastplot + theme_tufte()
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

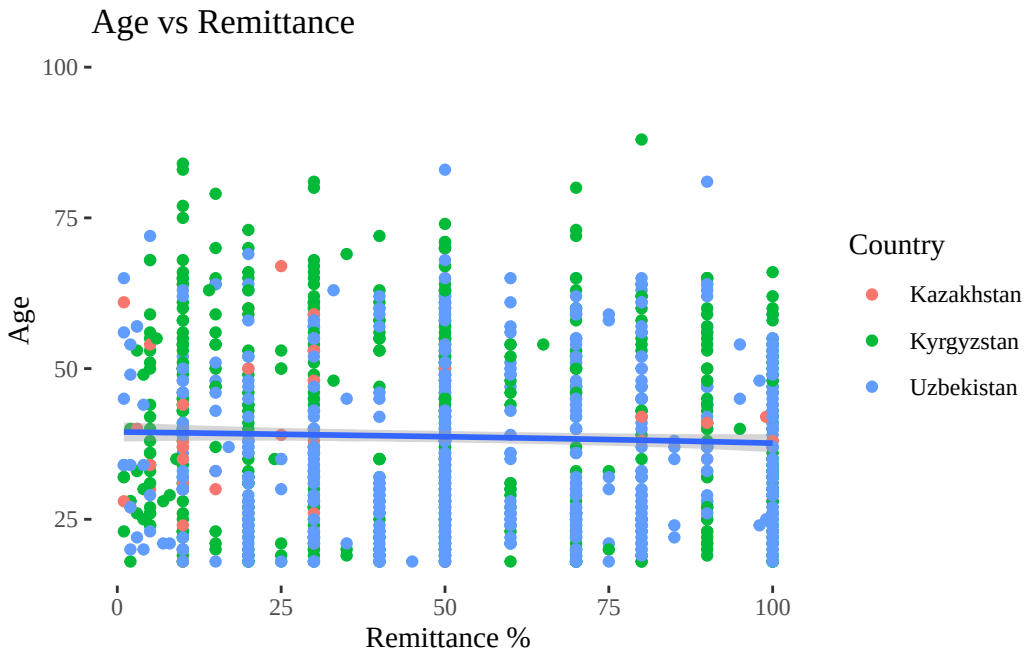


```
lastplot + theme_wsj()
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

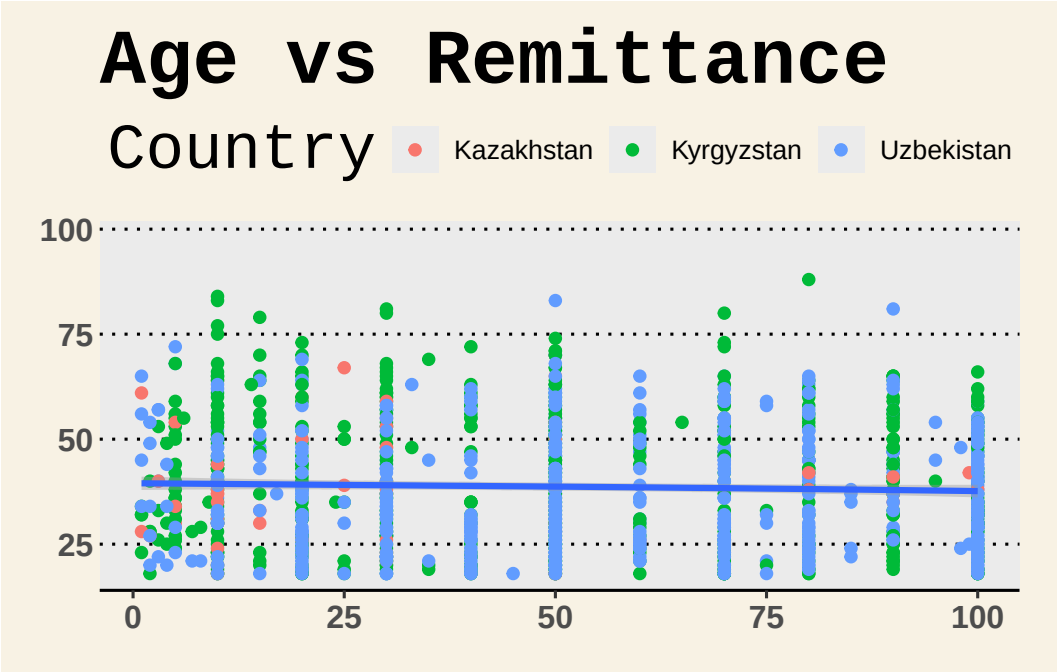


```
# then with Rcolorbrewer

lastplot + theme_economist() + scale_color_brewer(palette = "Set3")
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'

Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

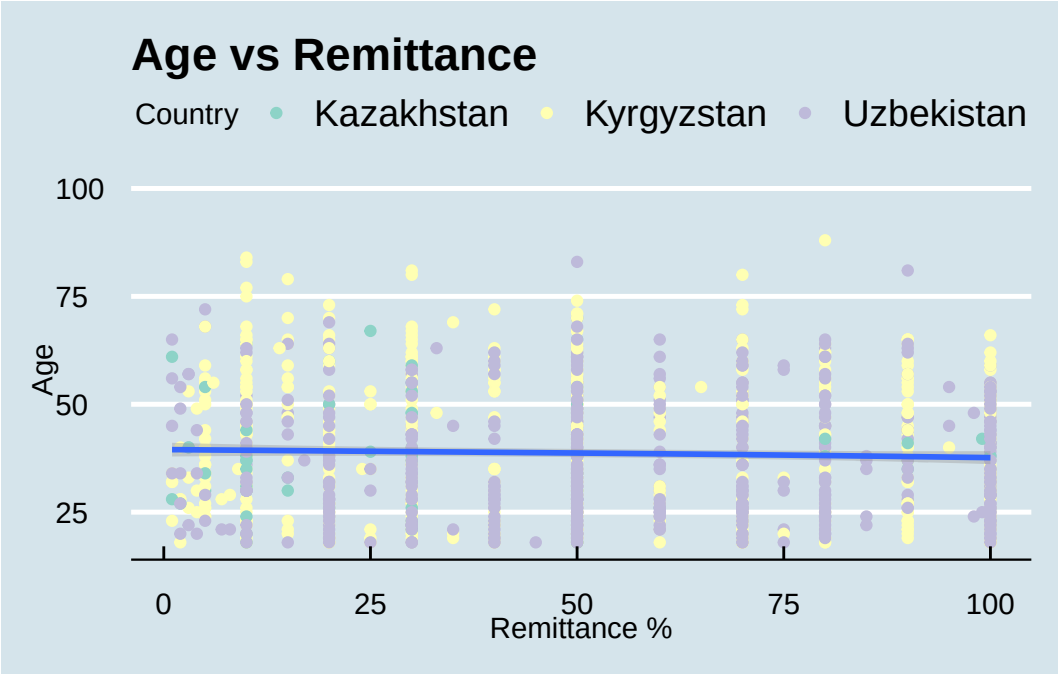


```
lastplot + theme_tufte() + scale_color_brewer(palette = "Dark2")
```

```
`geom_smooth()` using method = 'gam' and formula = 'y ~ s(x, bs = "cs")'
```

```
Warning: Removed 13837 rows containing non-finite outside the scale range
(`stat_smooth()`).
Removed 13837 rows containing missing values or values outside the scale range
(`geom_point()`).
```

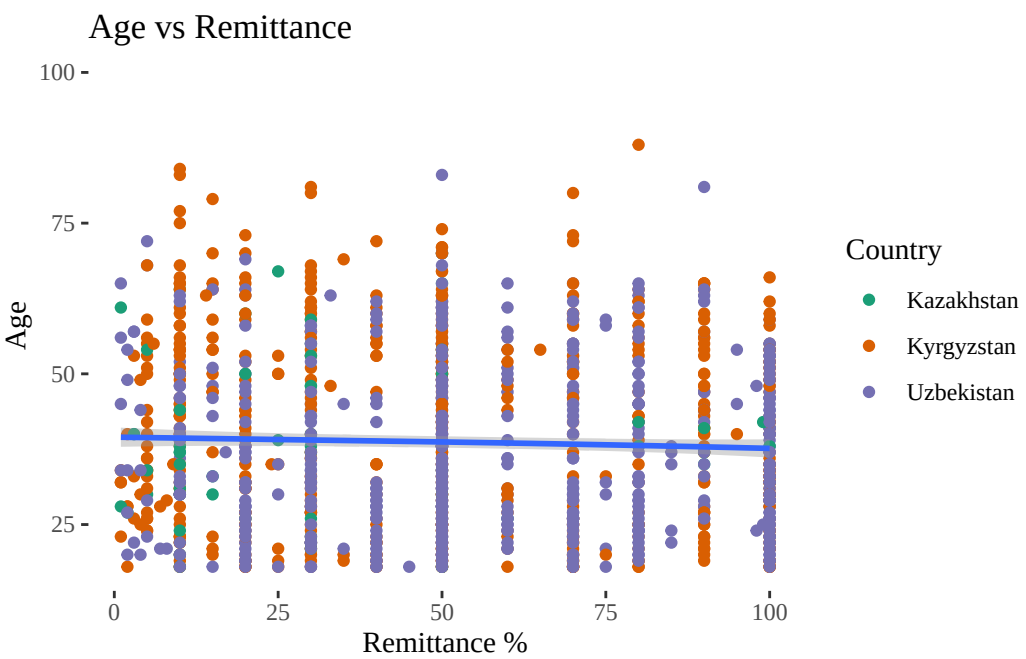

10.10 Интерактивность

Мы быстро покажем, как добавить немного интерактивности в график. Существуют инструменты для создания полностью интерактивных сайтов, в частности Shiny для R (а теперь и для Python). Подробнее см. мой мастер-класс Визуализация данных 2.

```
myplot <- ggplot(
  data = my_final_data,
  mapping = aes(
    x = Remit, y = Age,
    # here we add interactive aesthetics
    tooltip = paste(Country,Marital)
  )
) +
  geom_point_interactive(
    size = 1, hover_nearest = TRUE
  )

interactive_plot <- girafe(ggobj = myplot)
```

```
Warning: Removed 13837 rows containing missing values or values outside the scale range
(`geom_interactive_point()`).
```

```
htmltools::save_html(interactive_plot, "/home/ryan/R/ggiraph-2.html")
```

10.11 Обработка данных для сравнения во времени

Для того чтобы, например, изучить изменения во времени в вопросе «Направление» — или в любой другой переменной в этом наборе данных — нам нужно немного поработать над обработкой данных, выходящей за рамки исходных значений, которые мы использовали в приведенных выше столбчатых диаграммах.

В этом примере процент людей, считающих, что их страна движется в правильном направлении, рассчитывается путем извлечения значений и отбрасывания пропущенных значений (рассматриваются только ответы «Правильно» и «Неправильно»). Код делает это для каждой из девяти комбинаций страны и года, а затем вставляет результаты в небольшую матрицу, чтобы мы могли построить график.

Это один из подходов к решению проблемы, среди нескольких других возможностей. Например, можно переименовать и реструктурировать данные, чтобы упростить итерацию по записям и автоматизировать часть этого кодирования. Можно также перекодировать данные в бинарные ответы «да/нет», 0-1, чтобы упростить математические вычисления с пропорциями. В приведенном ниже подходе используется пакет tidyverse *forcats*, предназначенный для работы с категориальными данными. Для моего стиля математических вычислений ручное построение матрицы кажется наиболее понятным способом решения этой задачи.

```r
# compute percentages

my_final_data$Direction_recode <- as.factor(Direction_recode)

attach(my_final_data)
```

```
The following objects are masked from my_final_data (pos = 3):

    Age, China_Favor, Country, Country_Fin_Sit, Direction,
    Direction_recode, Education, Employment, Employment_recode,
    Employment_recode2, Family_Fin_Sit, Family_Fin_Sit_recode,
    Language, Main_News, Marital, Marital_recode, Remit, Russia_Favor,
    Sex, USA_Favor, Year

The following objects are masked from my_final_data (pos = 4):

    Age, China_Favor, Country, Country_Fin_Sit, Direction, Education,
    Employment, Family_Fin_Sit, Language, Main_News, Marital, Remit,
    Russia_Favor, Sex, USA_Favor, Year

The following objects are masked from my_final_data (pos = 5):

    Age, China_Favor, Country, Country_Fin_Sit, Direction, Education,
    Employment, Family_Fin_Sit, Language, Main_News, Marital, Remit,
    Russia_Favor, Sex, USA_Favor, Year
```

```r
mean(as.numeric(Direction_recode), na.rm=TRUE)
```

```
[1] 1.158222
```

```r
levels(my_final_data$Direction_recode)
```

```
[1] "Right direction" "Wrong direction"
```

```r
# forcats

fct_count(Direction_recode, sort = FALSE, prop = TRUE)
```

```
# A tibble: 3 x 3
  f                    n     p
  <fct>            <int> <dbl>
1 Right direction   9885 0.658
2 Wrong direction   1858 0.124
3 <NA>              3286 0.219
```

```r
mytable <- fct_count(Direction_recode, sort = FALSE, prop = FALSE)

Direction_percent <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

# fct_match(Direction_recode, "Right direction")

# Now do a matrix of these

Uz18<- my_final_data |> filter(Country=="Uzbekistan" & Year==2018)
Uz20<- my_final_data |> filter(Country=="Uzbekistan" & Year==2020)
Uz22<- my_final_data |> filter(Country=="Uzbekistan" & Year==2022)

Kz18<- my_final_data |> filter(Country=="Kazakhstan" & Year==2018)
Kz20<- my_final_data |> filter(Country=="Kazakhstan" & Year==2020)
Kz22<- my_final_data |> filter(Country=="Kazakhstan" & Year==2022)

Kg18<- my_final_data |> filter(Country=="Kyrgyzstan" & Year==2018)
Kg20<- my_final_data |> filter(Country=="Kyrgyzstan" & Year==2020)
Kg22<- my_final_data |> filter(Country=="Kyrgyzstan" & Year==2022)

# setup our matrix

Direction_pct_matrix <- data.frame(matrix(0,3,3))
rownames(Direction_pct_matrix) = c("Kazakhstan", "Kyrgyzstan", "Uzbekistan")
colnames(Direction_pct_matrix) = c("2018", "2020", "2022")

mytable <- fct_count(Kz18$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[1,1] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

mytable <- fct_count(Kz20$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[1,2] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

mytable <- fct_count(Kz22$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[1,3] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

mytable <- fct_count(Kg18$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[2,1] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

mytable <- fct_count(Kg20$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[2,2] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

mytable <- fct_count(Kg22$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[2,3] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

mytable <- fct_count(Uz18$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[3,1] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])

mytable <- fct_count(Uz20$Direction_recode, sort = FALSE, prop = FALSE)
Direction_pct_matrix[3,2] <- mytable[1,2]/(mytable[1,2]+mytable[2,2])
```

```r
# this was the not asked question in Uzbekistan in 2022, so leave it alone,
↪  code as NA

mytable <- fct_count(Uz22$Direction_recode, sort = FALSE, prop = FALSE)

Direction_pct_matrix[3,3] <- NA

Direction_pct_matrix <- cbind(Direction_pct_matrix, Country=c("Kazakhstan",
↪  "Kyrgyzstan", "Uzbekistan"))

Direction_long <- pivot_longer(Direction_pct_matrix, !Country,
↪  names_to="Year", values_to = "Value")

Direction_long$Year <- as.numeric(Direction_long$Year)

ggplot(Direction_long, aes(x=Year, y=Value, color=Country)) +
  geom_line()
```

```
Warning: Removed 1 row containing missing values or values outside the scale range
(`geom_line()`).
```

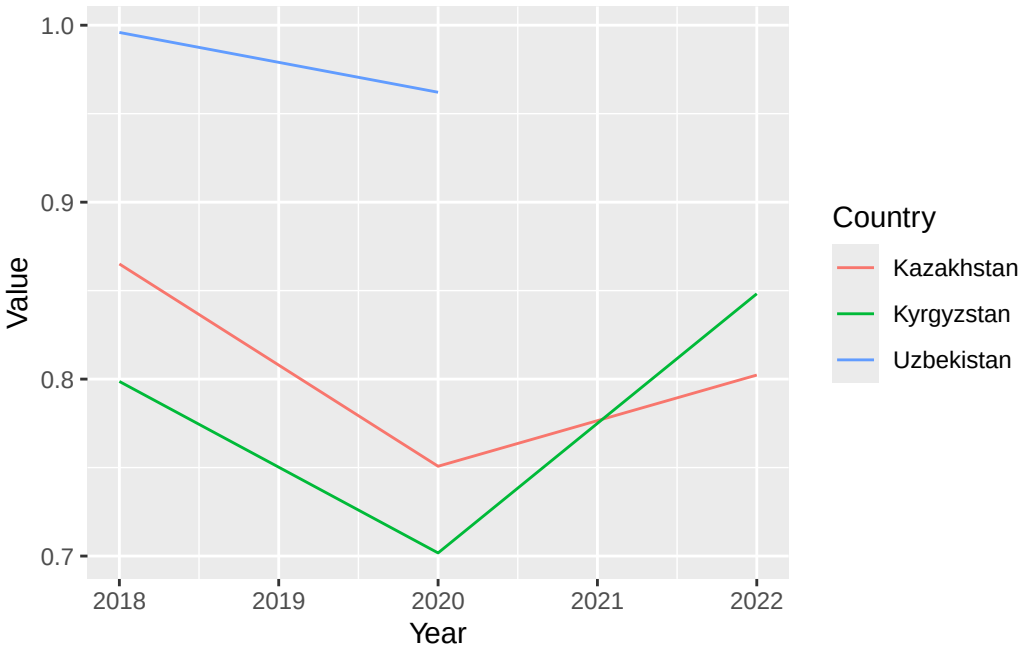


```r
ggplot(Direction_long, aes(x=Year, y=Value, color=Country)) +
  geom_line() + theme_tufte() + scale_color_brewer(palette = "Dark2") +
  labs(title="Right Direction over time", y="Percentage")
```

```
Warning: Removed 1 row containing missing values or values outside the scale range
(`geom_line()`).
```

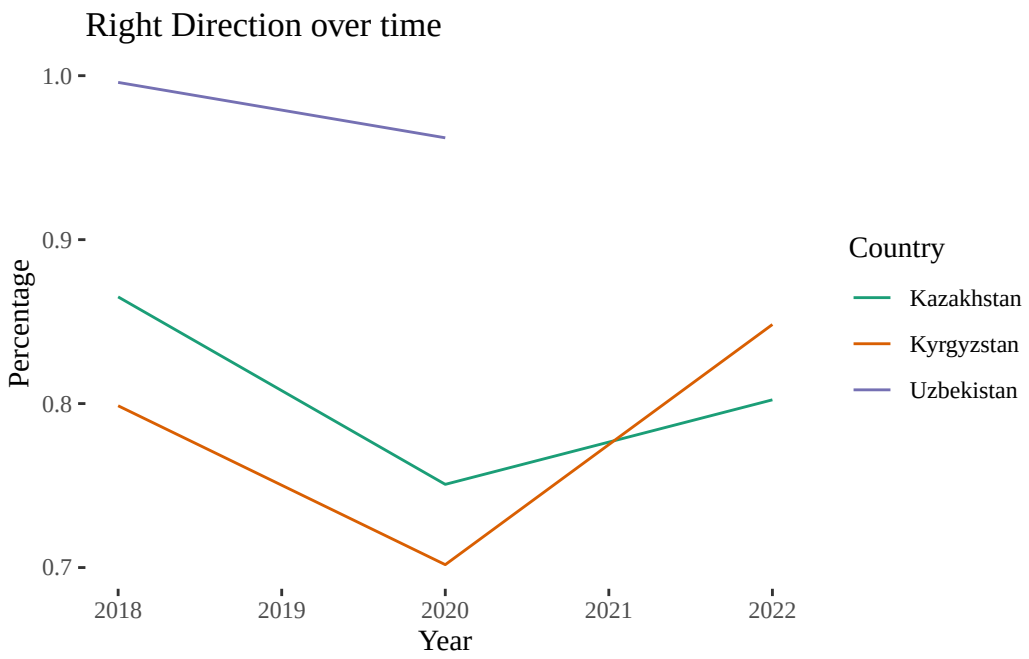

11 Дальнейший статистический анализ

11.1 Пошаговая регрессия

В качестве еще одного краткого примера статистического анализа мы можем попробовать пошаговую регрессию для прогнозирования ответа на вопрос о правильном направлении. Логистическая регрессия — подходящий метод, когда результат представляет собой бинарный выбор (да/нет, верно/неверно, правильно/неверно).

```
lm(data=my_final_data, Remit ~ .)
```

```
Call:
lm(formula = Remit ~ ., data = my_final_data)

Coefficients:
                                                  (Intercept)
                                                    1.025e+02
                                                       SexMale
                                                     -5.143e+00
                                                            Age
                                                     8.998e-03
                                                 MaritalSingle
                                                     -3.198e+00
                                  MaritalWidowed or divorced
                                                     -3.078e+00
                                    EducationComplete school
                                                     2.140e+00
```

```
EducationComplete vocational - vocational school, lyceum, etc.
                                                    -1.424e+00
                                   EducationFinished school
                                                     3.207e+00
                        EducationIncomplete higher education
                                                     4.132e-01
                                 EducationIncomplete school
                                                     1.371e+01
                    EducationIncomplete vocational education
                                                     3.607e+00
                                         EducationNo education
                                                     2.024e+01
        EducationVocational (vocational school, lyceum etc.)
                                                     2.742e+00
                        EmploymentA housewife / househusband
                                                    -7.413e+00
                                           EmploymentA student
                                                     1.090e+00
                                             EmploymentRetired
                                                    -1.561e+01
        EmploymentUnemployed and actively seeking employment
                                                     1.931e+00
     EmploymentUnemployed and not actively seeking employment
                                                     7.137e+00
                                 EmploymentWorking full-time
                                                    -1.231e+01
                                 EmploymentWorking part-time
                                                    -1.316e+01
                                    DirectionWrong direction
                                                     5.883e-01
                                   China_FavorRefused (vol.)
                                                     2.836e+01
                                 China_FavorSomewhat Favorable
                                                    -4.770e-01
                               China_FavorSomewhat Unfavorable
                                                     7.221e+00
                                   China_FavorVery Favorable
                                                     2.588e+00
                                 China_FavorVery Unfavorable
                                                     7.166e-01
                                  Russia_FavorRefused (vol.)
                                                    -8.448e+01
                                Russia_FavorSomewhat Favorable
                                                    -1.045e+00
                              Russia_FavorSomewhat Unfavorable
                                                    -4.756e+00
                                  Russia_FavorVery Favorable
                                                     1.593e+00
```

Russia_FavorVery Unfavorable
-9.045e+00
USA_FavorRefused (vol.)
4.003e+01
USA_FavorSomewhat Favorable
-3.250e+00
USA_FavorSomewhat Unfavorable
-6.396e+00
USA_FavorVery Favorable
3.120e-01
USA_FavorVery Unfavorable
4.342e+00
Main_NewsFamily, friends, or neighbors
-3.346e+01
Main_NewsInternet
-3.057e+01
Main_NewsInternet: blogs, others
-3.226e+01
Main_NewsNon-government newspapers published in our country
-5.251e+01
Main_NewsNone / Not interested in news (vol.)
-4.714e+01
Main_NewsOther (vol.)
-1.381e+01
Main_NewsOur country's national television stations
-2.940e+01
Main_NewsOur government's newspapers
-4.035e+01
Main_NewsRadio
2.402e+01
Main_NewsReligious services or literature
-3.556e+01
Main_NewsRussian television stations
-5.486e+01
Main_NewsSocial media sites or messengers
-3.389e+01
LanguageKarakalplak
-1.140e+01
LanguageKazakh
-2.420e+01
LanguageKyrgyz
-2.518e+01
LanguageOther
-8.257e+01
LanguageOther (vol.)
-1.804e+01
LanguageRussian
-2.891e+01

```
                                   LanguageTajik
                                        6.440e+00
                                 LanguageTurkmen
                                       -1.027e+02
                                   LanguageUzbek
                                       -6.066e+00
              Country_Fin_SitDon't Know (vol.)
                                       -6.027e+00
                    Country_Fin_SitMuch Better
                                       -1.649e+00
                     Country_Fin_SitMuch Worse
                                        1.232e+01
                 Country_Fin_SitRefused (vol.)
                                        3.010e+01
                Country_Fin_SitSomewhat Better
                                        4.447e+00
                 Country_Fin_SitSomewhat Worse
                                        6.906e+00
                   Family_Fin_SitBecome Better
                                       -6.082e+00
                    Family_Fin_SitBecome Worse
                                       -7.769e+00
                     Family_Fin_SitMuch better
                                       -5.003e+00
                      Family_Fin_SitMuch worse
                                       -6.092e+00
                 Family_Fin_SitSomewhat better
                                       -4.648e+00
                  Family_Fin_SitSomewhat worse
                                       -4.229e+00
                 Family_Fin_SitStayed the Same
                                       -5.070e+00
                             CountryKyrgyzstan
                                        1.216e+01
                             CountryUzbekistan
                                        8.194e+00
                                           Year
                                             NA
                          Marital_recodeSingle
                                             NA
          Marital_recodeWidowed or divorced
                                             NA
Employment_recodeA housewife / househusband
                                             NA
                   Employment_recodeA student
                                             NA
                     Employment_recodeRetired
                                             NA
```

```
    Employment_recodeUnemployed and actively seeking employment
                                                             NA
Employment_recodeUnemployed and not actively seeking employment
                                                             NA
                              Employment_recodeWorking full-time
                                                             NA
                              Employment_recodeWorking part-time
                                                             NA
                                     Employment_recode2Housewife
                                                             NA
                                       Employment_recode2Retired
                                                             NA
                                    Employment_recode2Unemployed
                                                             NA
                                       Employment_recode2Working
                                                             NA
                                 Direction_recodeWrong direction
                                                             NA
                                       Family_Fin_Sit_recodeSame
                                                             NA
                                     Family_Fin_Sit_recodeWorse
                                                             NA
```

```r
lm(data=my_final_data, Remit ~ Year)
```

```
Call:
lm(formula = Remit ~ Year, data = my_final_data)

Coefficients:
(Intercept)         Year
   4879.037       -2.389
```

```r
regression_output <- lm(Remit ~ Sex + Language, data=my_final_data)
summary(regression_output)
```

```
Call:
lm(formula = Remit ~ Sex + Language, data = my_final_data)

Residuals:
    Min      1Q  Median      3Q     Max
-61.499 -22.364  -1.316  20.770  70.193

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)             56.620     29.164   1.941 0.052443 .
SexMale                 -6.620      1.734  -3.817 0.000142 ***
```

```
LanguageKarakalpak       -6.238     30.218  -0.206 0.836483
LanguageKarakalplak       5.352     30.541   0.175 0.860916
LanguageKazakh          -14.301     29.763  -0.480 0.630972
LanguageKyrgyz           -5.303     29.160  -0.182 0.855724
LanguageOther           -30.000     41.171  -0.729 0.466347
LanguageOther (vol.)     -5.803     31.123  -0.186 0.852127
LanguageRefused (vol.)   -6.620     41.207  -0.161 0.872405
LanguageRussian         -20.193     29.293  -0.689 0.490751
LanguageTajik            -6.007     29.547  -0.203 0.838931
LanguageTurkmen         -41.080     33.636  -1.221 0.222212
LanguageUzbek             5.879     29.158   0.202 0.840237
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 29.11 on 1179 degrees of freedom
  (13837 observations deleted due to missingness)
Multiple R-squared:  0.08179,   Adjusted R-squared:  0.07244
F-statistic: 8.752 on 12 and 1179 DF,  p-value: 3.504e-16
```

```r
regression_output_all_demographic <- lm(Remit ~ Sex + Age + Language +
 ↪  Employment + Education + Country + Year, data=my_final_data)
summary(regression_output_all_demographic)
```

```
Call:
lm(formula = Remit ~ Sex + Age + Language + Employment + Education +
    Country + Year, data = my_final_data)

Residuals:
    Min      1Q  Median      3Q     Max
-62.284 -21.452  -0.478  20.883  74.774

Coefficients:
                                                                  Estimate
(Intercept)                                                      -71.97361
SexMale                                                           -3.68612
Age                                                                0.07580
LanguageKarakalpak                                               -17.81780
LanguageKarakalplak                                               -5.15660
LanguageKazakh                                                   -20.10909
LanguageKyrgyz                                                   -21.52807
LanguageOther                                                    -39.59865
LanguageOther (vol.)                                             -16.25928
LanguageRefused (vol.)                                           -17.19801
LanguageRussian                                                  -30.42818
LanguageTajik                                                    -15.26527
LanguageTurkmen                                                  -45.06972
LanguageUzbek                                                     -6.81348
```

EmploymentA housewife / househusband	-12.57774
EmploymentA student	-6.50282
EmploymentDon't Know (vol.)	-25.14740
EmploymentRefused (vol.)	42.82873
EmploymentRetired	-20.65655
EmploymentUnemployed and actively seeking employment	-3.45304
EmploymentUnemployed and not actively seeking employment	-2.05662
EmploymentWorking full-time	-17.75971
EmploymentWorking part-time	-16.95468
EducationComplete school	-3.18996
EducationComplete vocational - vocational school, lyceum, etc.	0.38482
EducationFinished school	5.16304
EducationIncomplete higher education	0.87363
EducationIncomplete school	5.74694
EducationIncomplete vocational education	3.20953
EducationNo education	-11.19255
EducationVocational (vocational school, lyceum etc.)	2.93201
CountryKyrgyzstan	8.43419
CountryUzbekistan	2.44885
Year	0.07083
	Std. Error
(Intercept)	1704.63557
SexMale	1.91440
Age	0.07944
LanguageKarakalpak	29.71893
LanguageKarakalplak	30.14348
LanguageKazakh	28.76249
LanguageKyrgyz	28.65775
LanguageOther	40.47050
LanguageOther (vol.)	30.19320
LanguageRefused (vol.)	40.38517
LanguageRussian	28.47748
LanguageTajik	29.03213
LanguageTurkmen	32.92324
LanguageUzbek	28.65380
EmploymentA housewife / househusband	3.79413
EmploymentA student	4.39810
EmploymentDon't Know (vol.)	20.15057
EmploymentRefused (vol.)	28.29363
EmploymentRetired	3.91040
EmploymentUnemployed and actively seeking employment	4.05323
EmploymentUnemployed and not actively seeking employment	4.21557
EmploymentWorking full-time	3.41131
EmploymentWorking part-time	3.90417
EducationComplete school	3.06981
EducationComplete vocational - vocational school, lyceum, etc.	3.20755
EducationFinished school	3.59326
EducationIncomplete higher education	4.30015

```
EducationIncomplete school                                          5.43586
EducationIncomplete vocational education                            4.38735
EducationNo education                                              16.48783
EducationVocational (vocational school, lyceum etc.)                3.84373
CountryKyrgyzstan                                                   5.46578
CountryUzbekistan                                                   5.65653
Year                                                                0.84373
                                                                  t value Pr(>|t|)
(Intercept)                                                        -0.042 0.966329
SexMale                                                            -1.925 0.054415
Age                                                                 0.954 0.340186
LanguageKarakalpak                                                 -0.600 0.548928
LanguageKarakalplak                                                -0.171 0.864200
LanguageKazakh                                                     -0.699 0.484603
LanguageKyrgyz                                                     -0.751 0.452677
LanguageOther                                                      -0.978 0.328053
LanguageOther (vol.)                                               -0.539 0.590330
LanguageRefused (vol.)                                             -0.426 0.670297
LanguageRussian                                                    -1.068 0.285518
LanguageTajik                                                      -0.526 0.599123
LanguageTurkmen                                                    -1.369 0.171286
LanguageUzbek                                                      -0.238 0.812089
EmploymentA housewife / househusband                               -3.315 0.000945
EmploymentA student                                                -1.479 0.139532
EmploymentDon't Know (vol.)                                        -1.248 0.212293
EmploymentRefused (vol.)                                            1.514 0.130369
EmploymentRetired                                                  -5.282 1.52e-
07
EmploymentUnemployed and actively seeking employment               -0.852 0.394433
EmploymentUnemployed and not actively seeking employment           -0.488 0.625740
EmploymentWorking full-time                                        -5.206 2.28e-
07
EmploymentWorking part-time                                        -4.343 1.53e-
05
EducationComplete school                                           -1.039 0.298956
EducationComplete vocational - vocational school, lyceum, etc.      0.120 0.904525
EducationFinished school                                            1.437 0.151025
EducationIncomplete higher education                                0.203 0.839043
EducationIncomplete school                                          1.057 0.290628
EducationIncomplete vocational education                            0.732 0.464595
EducationNo education                                              -0.679 0.497377
EducationVocational (vocational school, lyceum etc.)                0.763 0.445736
CountryKyrgyzstan                                                   1.543 0.123082
CountryUzbekistan                                                   0.433 0.665150
Year                                                                0.084 0.933108

(Intercept)
SexMale                                                            .
```

```
Age
LanguageKarakalpak
LanguageKarakalplak
LanguageKazakh
LanguageKyrgyz
LanguageOther
LanguageOther (vol.)
LanguageRefused (vol.)
LanguageRussian
LanguageTajik
LanguageTurkmen
LanguageUzbek
EmploymentA housewife / househusband                          ***
EmploymentA student
EmploymentDon't Know (vol.)
EmploymentRefused (vol.)
EmploymentRetired                                             ***
EmploymentUnemployed and actively seeking employment
EmploymentUnemployed and not actively seeking employment
EmploymentWorking full-time                                   ***
EmploymentWorking part-time                                   ***
EducationComplete school
EducationComplete vocational - vocational school, lyceum, etc.
EducationFinished school
EducationIncomplete higher education
EducationIncomplete school
EducationIncomplete vocational education
EducationNo education
EducationVocational (vocational school, lyceum etc.)
CountryKyrgyzstan
CountryUzbekistan
Year
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 27.96 on 1158 degrees of freedom
  (13837 observations deleted due to missingness)
Multiple R-squared:  0.1682,    Adjusted R-squared:  0.1445
F-statistic: 7.096 on 33 and 1158 DF,  p-value: < 2.2e-16

backward_model <- step(regression_output_all_demographic, direction =
 ↪  "backward")

Start:  AIC=7973.94
Remit ~ Sex + Age + Language + Employment + Education + Country +
    Year

             Df Sum of Sq    RSS    AIC
```

```
- Education   8      4919 910094 7964.4
- Year        1         6 905181 7971.9
- Age         1       712 905887 7972.9
<none>                    905176 7973.9
- Country     2      3399 908575 7974.4
- Sex         1      2898 908074 7975.7
- Language   11     35971 941146 7998.4
- Employment  9     48953 954128 8018.7

Step:  AIC=7964.4
Remit ~ Sex + Age + Language + Employment + Country + Year

             Df Sum of Sq    RSS    AIC
- Age         1       691 910785 7963.3
<none>                    910094 7964.4
- Country     2      3330 913425 7964.7
- Year        1      2187 912281 7965.3
- Sex         1      2728 912822 7966.0
- Language   11     37583 947678 7990.6
- Employment  9     52830 962924 8013.7

Step:  AIC=7963.3
Remit ~ Sex + Language + Employment + Country + Year

             Df Sum of Sq    RSS    AIC
<none>                    910785 7963.3
- Country     2      3419 914204 7963.8
- Sex         1      2591 913376 7964.7
- Year        1      2619 913404 7964.7
- Language   11     37645 948430 7989.6
- Employment  9     57584 968369 8018.4
```

```r
# Print the summary of the selected model

summary(backward_model)
```

```
Call:
lm(formula = Remit ~ Sex + Language + Employment + Country +
    Year, data = my_final_data)

Residuals:
    Min      1Q  Median      3Q     Max
-63.585 -22.008  -0.736  21.355  75.324

Coefficients:
                                                          Estimate Std. Error
(Intercept)                                             2101.7939  1107.4362
```

SexMale	-3.4720	1.9056
LanguageKarakalpak	-14.2290	29.6101
LanguageKarakalplak	-3.4237	29.9879
LanguageKazakh	-17.6569	28.6852
LanguageKyrgyz	-19.0046	28.5893
LanguageOther	-34.8426	40.0542
LanguageOther (vol.)	-12.5691	30.0969
LanguageRefused (vol.)	-11.1582	40.0508
LanguageRussian	-27.9790	28.4033
LanguageTajik	-12.9188	28.9693
LanguageTurkmen	-43.4653	32.8627
LanguageUzbek	-4.1061	28.5924
EmploymentA housewife / househusband	-13.4788	3.7125
EmploymentA student	-7.6983	3.9334
EmploymentDon't Know (vol.)	-23.7324	20.0477
EmploymentRefused (vol.)	44.4887	28.2298
EmploymentRetired	-19.3761	3.2252
EmploymentUnemployed and actively seeking employment	-4.1640	3.9998
EmploymentUnemployed and not actively seeking employment	-2.6289	4.1481
EmploymentWorking full-time	-18.3147	3.3162
EmploymentWorking part-time	-17.5594	3.8390
CountryKyrgyzstan	8.4415	5.4478
CountryUzbekistan	2.6419	5.6115
Year	-1.0043	0.5483

	t value	Pr(>|t|)	
(Intercept)	1.898	0.057957	.
SexMale	-1.822	0.068709	.
LanguageKarakalpak	-0.481	0.630931	
LanguageKarakalplak	-0.114	0.909123	
LanguageKazakh	-0.616	0.538318	
LanguageKyrgyz	-0.665	0.506346	
LanguageOther	-0.870	0.384541	
LanguageOther (vol.)	-0.418	0.676302	
LanguageRefused (vol.)	-0.279	0.780599	
LanguageRussian	-0.985	0.324799	
LanguageTajik	-0.446	0.655718	
LanguageTurkmen	-1.323	0.186216	
LanguageUzbek	-0.144	0.885835	
EmploymentA housewife / househusband	-3.631	0.000295	***
EmploymentA student	-1.957	0.050564	.
EmploymentDon't Know (vol.)	-1.184	0.236735	
EmploymentRefused (vol.)	1.576	0.115308	
EmploymentRetired	-6.008	2.51e-09	***
EmploymentUnemployed and actively seeking employment	-1.041	0.298069	
EmploymentUnemployed and not actively seeking employment	-0.634	0.526367	
EmploymentWorking full-time	-5.523	4.11e-08	***
EmploymentWorking part-time	-4.574	5.30e-06	***
CountryKyrgyzstan	1.550	0.121529	

```
CountryUzbekistan                                          0.471 0.637869
Year                                                      -1.832 0.067243 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 27.94 on 1167 degrees of freedom
  (13837 observations deleted due to missingness)
Multiple R-squared:  0.1631,    Adjusted R-squared:  0.1458
F-statistic: 9.473 on 24 and 1167 DF,  p-value: < 2.2e-16
```

12 Другие возможности

Мы даже не затронули алгоритмы машинного обучения. Для их эффективного использования с этими несколько несовершенными данными из реального мира потребуется еще более тщательная очистка данных. Но такие методы, как кластеризация, деревья решений, случайные леса и другие, могут эффективно группировать данные, выявлять закономерности и делать прогнозы. См. пакет tidymodels, упомянутый ниже.

13 Заключение

В анализе данных нет единой точки остановки. Продолжайте, пока не получите полное понимание данных и их взаимодействия с вопросами, на которые вы хотите ответить!

Дополнительные сведения о методах анализа данных см. в разделах Анализ данных 1 и Анализ данных 2.

13.1 R for Data Science

Для получения дополнительной информации об обработке данных обратитесь к книге R for Data Science. Также ознакомьтесь с пакетом tidymodels, предназначенным для моделирования и машинного обучения с использованием принципов tidyverse.